MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull

Visión general

R

- Página web: https://www.r-project.org/
- Repositorio principal: http://cran.r-project.org/ (Existen otros como Bioconductor y cada vez más se usa GitHub)
- Funcionalidades
  - Paquete estadístico para la gestión y análisis de datos
  - Lenguaje de programación
  - Herramienta de cálculo
- Ventajas:
  - Software gratuito y de código abierto
  - Gráficos adaptables y de gran calidad con poco esfuerzo.
  - Multitud de librerías con técnicas estadísticas avanzadas

Why R?

R versus Python

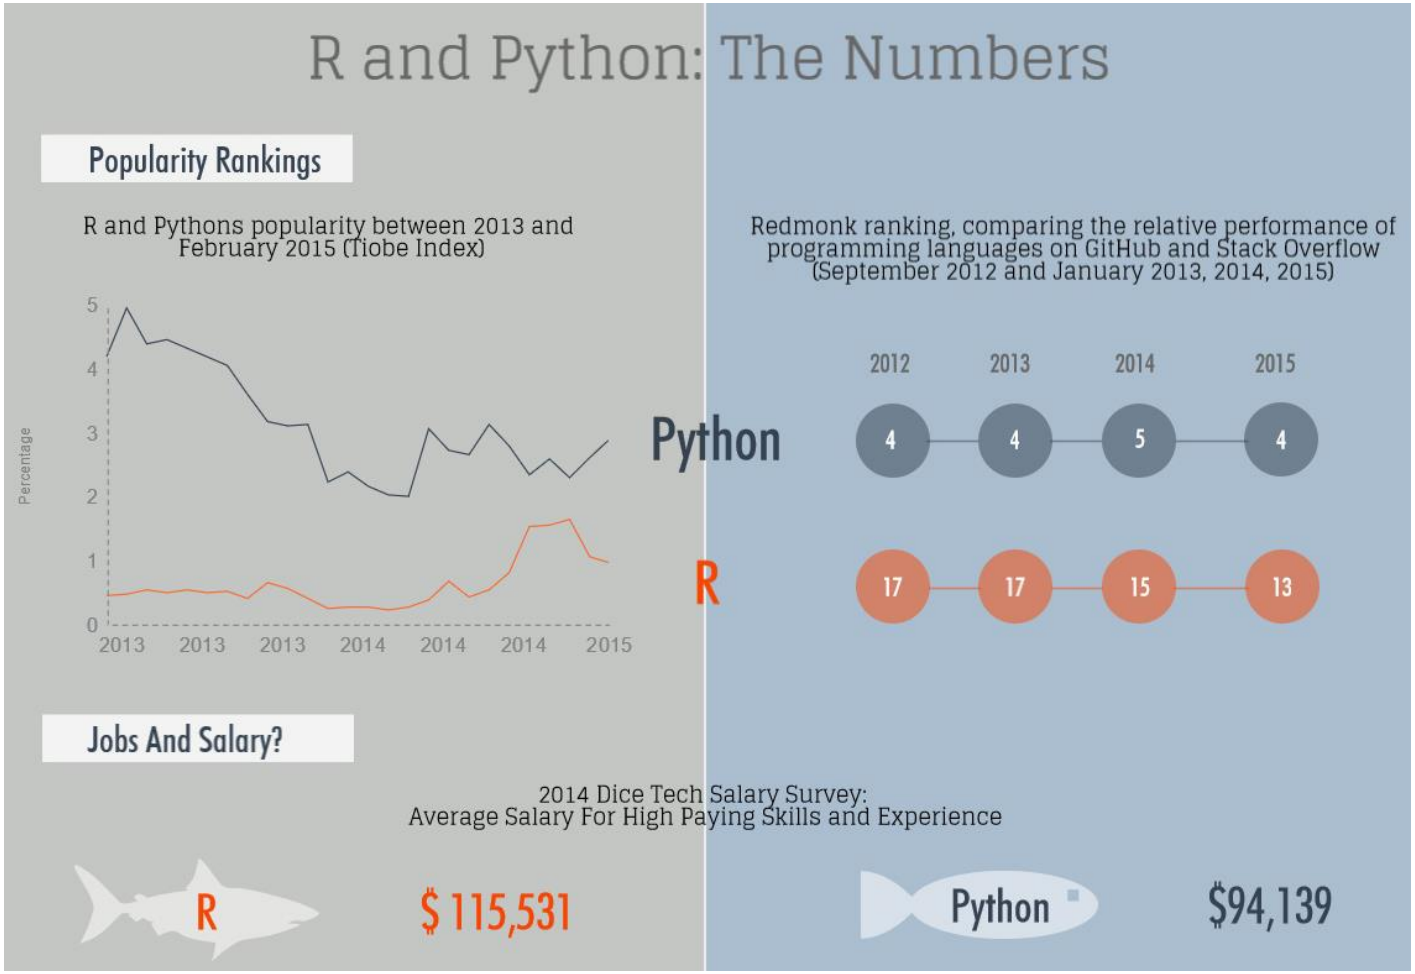

Source: https://www.datacamp.com/community/tutorials/r-or-python-for-data-analysis

Why R?

R versus Python

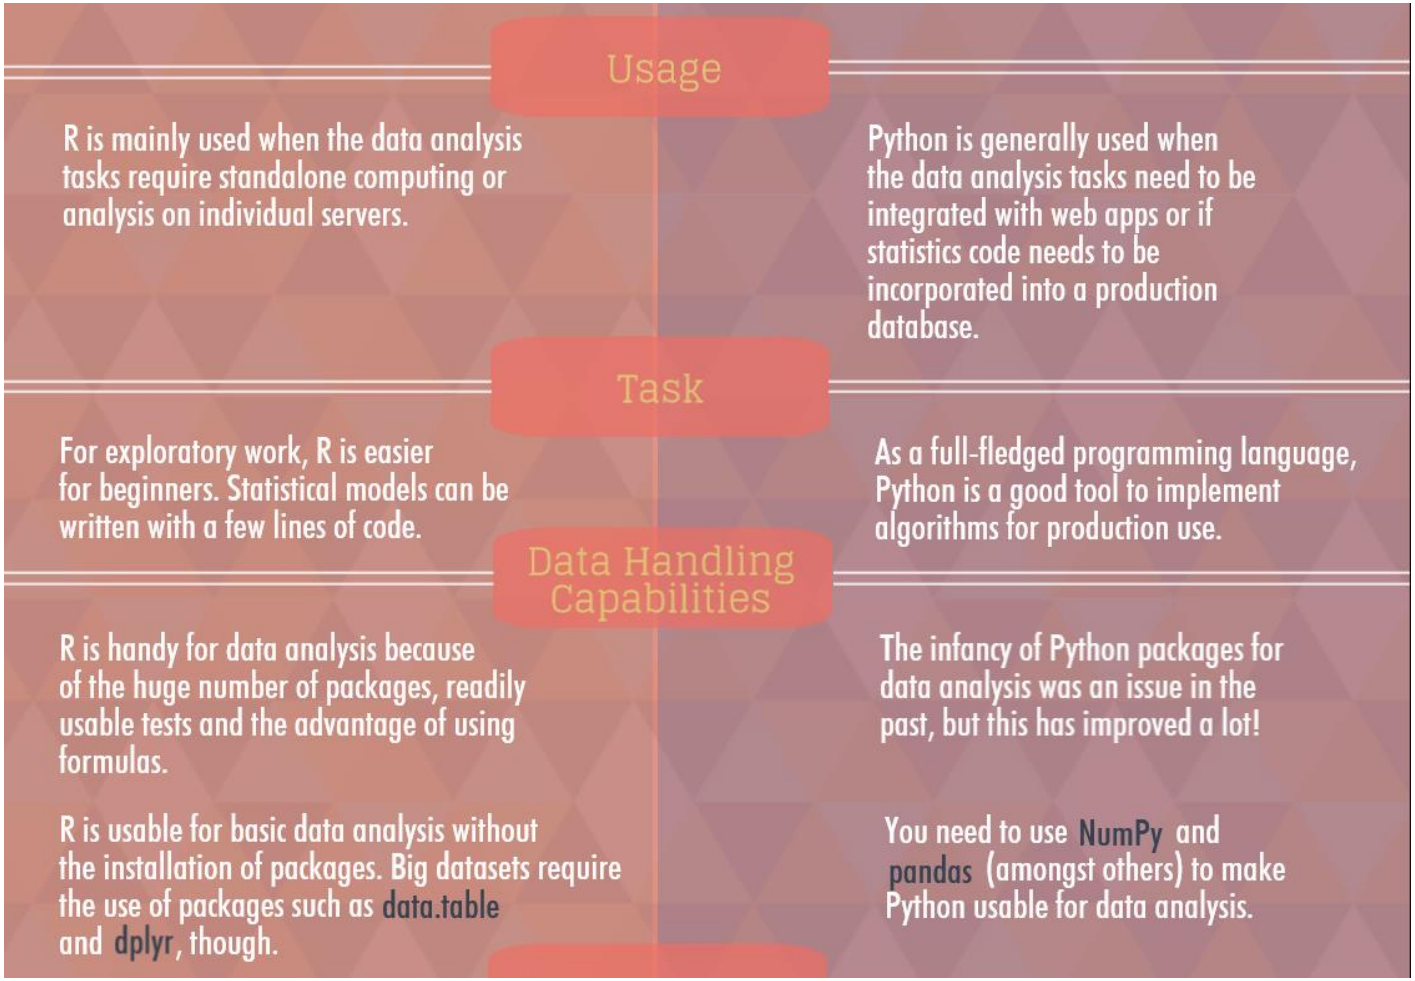

Source: https://www.datacamp.com/community/tutorials/r-or-python-for-data-analysis

Instalación

R

1. Ir a página web del repositorio ‘CRAN’: http://cran.r-project.org/
2. Clicar en Download R for *[SO]* (*[SO]* es Windows, Linux o Mac)
3. Windows
   - Clicar en base (instala paquetes básicos)
   - Clicar en Download R...
   - Descargar fichero y ejecutarlo
3. Mac
   - Escoger última versión
   - Descargar fichero y ejecutarlo
3. Linux
   - Escoger sistema operativo
   - Seguir instrucciones

Visión general

RStudio

- Página web: https://www.rstudio.com/
- Funcionalidades:
  - Interfaz más amigable para trabajar con R
  - Incorpora menús para funciones habituales
- Ventajas:
  - Creación de proyectos
  - Templates para Rmarkdown, Shiny….
  - Facilidades en escribir el código (ofrece alternativas mientras se escribe)
  - Código más legible (usa colores)
  - Visualización de los datos más directa y con filtros
  - Algunas funcionalidades son más inmediatas y no requieren de código (visualizar datos, instalar/cargar paquetes)

Instalación

RStudio

1. Ir a página web de RStudio: https://www.rstudio.com/
2. Clicar en *Download* RStudio
3. Clicar en *Rstudio Desktop* (opción *FREE*)
4. Descargar la primera opción que nos ofrezca que será la más reciente para las características de nuestro ordenador
5. Ejecutar el archivo descargado y seguir las instrucciones

Interfaz

R

Barra de Herramientas
Instalar paquetes,
guardar scripts, áreas de trabajo...

Script
Fichero de texto donde se guardan las instruccionesde análisis

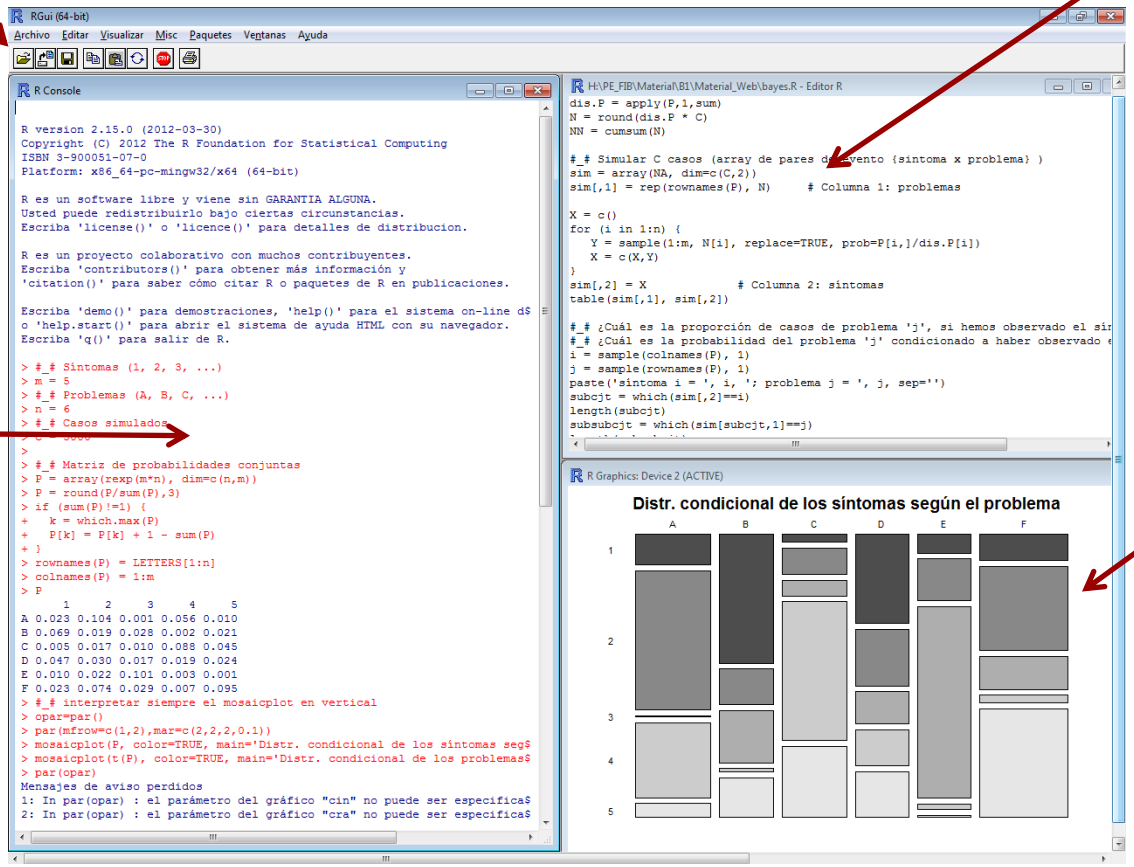

Consola
Donde se ejecutan las instrucciones

Ventana gráfica

Interfaz

RStudio

Barra de Herramientas
Guardar scripts, configuración del entorno...

Script
Fichero de texto donde se guardan las instrucciones de análisis

Entorno
Conjunto de objetos en memoria

Historial
Conjunto de instrucciones ejecutadas

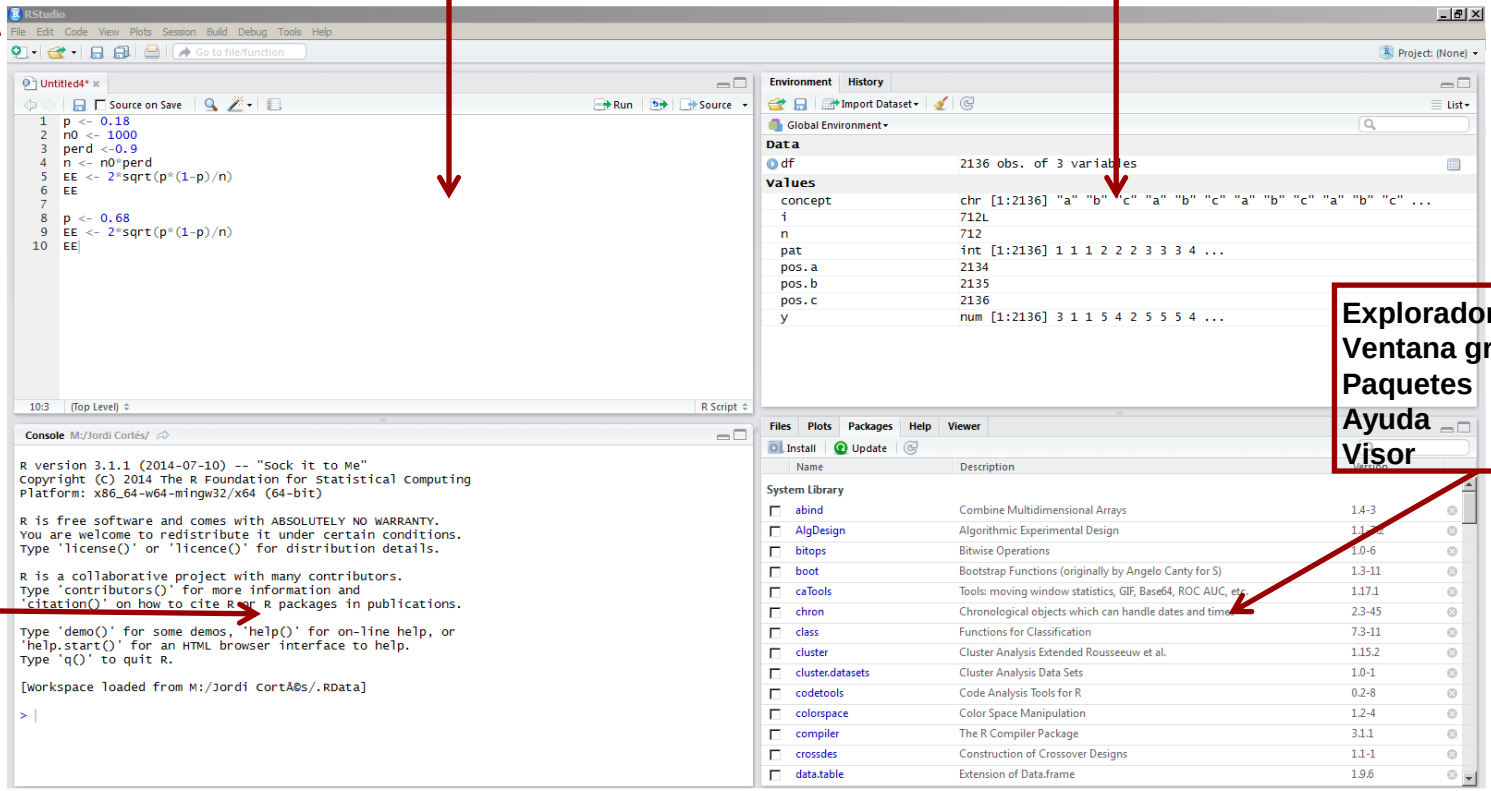

Explorador
Ventana gráfica
Paquetes
Ayuda
Visor

Consola
Salida de resultados

Primeros pasos

Funciones

- Realizan operaciones, análisis, gráficos, etc...
- Sintaxis: *`nombre de la función`*`(parámetros)`
- Ejemplo: `sum(2,3)`
- El orden de los parámetros puede ser:
  - Por defecto: `plot(5,5,"h")`
  - Indicando el nombre del parámetro: `plot(type="h", x=5, y=5)`

Primeros pasos

Asignaciones

- Los resultados de funciones o operaciones se pueden asignar a objetos con los símbolos “=“ o “<-”
- Sintaxis: `nombre_objeto <- valor_a_asignar`
- Ejemplo: `nota <- sum(2,3)`
- Para ver el contenido de un objeto (p.ej, nota), bastará con escribir su nombre en la consola

Primeros pasos

Ayuda y comentarios

- Se puede pedir ayuda de una función concreta (`?`) o de un tema general (`??`)
- Sintaxis: `?función` o `??"tema"` o `escribir en el menú de ayuda`
- Ejemplo: `?mean`

- En un código de análisis se pueden escribir comentarios para ayudar a su comprensión. Los comentarios no se ejecutan
- Sintaxis: `# Comentario`
- Ejemplo: `# La siguiente línea ajusta un modelo logístico`

Primeros pasos

Instalar paquetes

- R viene con unos paquetes/librerías base que permiten realizar unos análisis básicos. Existen multitud de paquetes que permiten análisis más sofisticados
- Los paquetes se deben instalar (una única vez en cada dispositivo) y cargar en memoria (en cada sesión)
- Sintaxis:
  - Instalar: `install.packages("nombre_del_paquete")`
  - Cargar: `library(nombre_del_paquete)`
- Ejemplo:
  - `install.packages("Hmisc")`
  - `library(Hmisc)`

Organización de la información

Tipos de objetos

- Los objetos simples pueden ser tipo ***numeric*** (real), ***integer*** (entero), ***character*** (cadena de caracteres), ***factor*** (categorías ordenadas o no), ***logical*** (TRUE, FALSE) …
- Se pueden organizar en distintas estructuras:
  - *Vectores*: conjunto ordenado del mismo tipo. Sintaxis: **`c`**. Ejemplo: `v <- c(1,2)`
  - *Matrices*: conjunto de filas y columnas de tipo numérico. Sintaxis: **`matrix`**. Ejemplo: `m <- matrix(c(1,2,3,4),ncol=2)`
  - *Data.frames*: conjunto de filas y columnas de cualquier tipo respetando que una misma columna sea del mismo tipo. Sintaxis: **`data.frame`**. Ejemplo: `df <- data.frame(v1=c(1,2),v2=c("a","b"))`
  - *Listas*: conjunto formado por combinaciones de las anteriores estructuras. Sintaxis: **`list`**. Ejemplo: `l <- list(v,m,df)`

Organización de la información

Acceso y modificación de datos

- Vectores
  - Acceso: `v[2]` [consultar 2º elemento]
  - Modificación: `v[2] <- 3` [modificar 2º elemento]
- Matrices
  - Acceso: `m[1,2]` [consultar 1ª fila, 2ª columna]
  - Modificación: `m[1,2] <- 5` [modificar 1ª fila, 2ª columna]
- Data.frames
  - Acceso: `m[2,1]` [consultar 2ª fila, 1ª columna]
  - Modificación: `m[2,1] <- "a"` [modificar 2ª fila, 1ª columna]
- Listas
  - Acceso: `l[[1]]` [consultar 1r elemento]
  - Modificación: `l[[1]] <- c(2,3)` [modificar 1r elemento]

Ejemplos

```
# Ayuda de una función o de un tema general
help(mean)
?median
help.search("histogram")

# Creación de un vector numérico y calcular su media
edad <- c(20,21,20,22,23,20,25,26,20,21)
edat.mean <- mean(edat)

# Creación de un vector de caracteres y hacer la tabla de frecuencias
genero <- c("h","h","h","h","h","h","h","d","d","d")
table(genero)

# Otros
ls()              # Ver los objetos en memoria
genero            # Ver el contenido del objeto genero
length(edad)      # Longitud del vector edad
class(genero)     # Clase del vector genero
```

Importación y exportación de datos

Lectura

- La lectura de un fichero, generalmente, retorna un *data.frame*
- Lectura de un fichero de texto (.txt)
  - Sintaxis: `read.table`
  - Ejemplo: `datos <- read.table("fichero.txt")`
- Lectura de un fichero de texto separado por comas (.csv)
  - Sintaxis: `read.csv (comas) o read.csv2 (punto y coma)`
  - Ejemplo: `datos <- read.csv("fichero.csv")`
- Lectura de un fichero SPSS (.sav)
  - Sintaxis: `read.spss (librería foreign)o read_spss (haven)`
  - Ejemplo: `datos <- read.spss("fichero.sav", to.data.frame=TRUE)`
- En la mayoría de casos, se requerirán más parámetros para realizar la lectura.
- Se pueden leer archivos en casi cualquier formato. Ver enlace.

Importación y exportación de datos

Escritura

- Generalmente guardaremos un *data.frame*
- Escritura de un objeto a un fichero de texo
  - Sintaxis: `write.table(objeto_a_guardar,nombre_fichero)`
  - Ejemplo: `write.table(df,"misdatos.txt")`
  - Parámetros opcionales:
    - `append` (¿se añade a un fichero existente?)
    - `quote` (¿se ponen comillas en los valores del fichero?)
    - `sep` (separardor entre columnas)
    - `dec` (separador decimal)
    - `row.names, col.names` (incluir nombres de filas y columnas)
    - …
- Para otros formatos, ver enlace.

R

Miscelánea

- R distingue mayúsculas y minúsculas. No es lo mismo el objeto *Datos* que *datos*
- Los valores ausentes (missings) los codifica como `NA` (*Not Available*) o `NaN` (*Not a Number*)
- La función `summary` es una función genérica que se pueda aplicar a un gran abanico de clases de objetos y nos proporciona un resumen de la información contenida en el mismo.
- Se pueden crear funciones propias con la instrucción `function` (ver `?function`)
- Los valores de tipo *character* o *factor* se deben poner entre comillas
- Las comillas simples (‘) y dobles (“) pueden usarse indistintamente.
- Se puede fijar el directorio de trabajo con `setwd("directorio")`
- Evitar el uso de acentos y símbolos como “*ñ*” o “*ç*”.

R

Tutoriales

- DataCamp
- Quick-R
- TutorialsPoint
- Edureka

MUBD

Màster Universitari en Enginyeria de Dades Massives (Big Data)

Estadística

laSalle ENG
Universitat Ramon Llull