

Hadoop ya no se usa.

RDMS – Base de datos relacional

HDFS – Hadoop Distribution File System

¿Qué es big data?

## 1. Introd al Big Data

**Volum** → **Moltes dades**

**Varietat** → **De molts tipus i fonts diferents**

**Velocidad** → **Analitzades ràpidament**

**Veracidad** → **Les dades son verdaderes**

**Valor** → **Aporten un valor (informació)**

Exemple Volumetria:

- Telescopis
- Sequenciador genètic
- Netflix: Anàlisi de recomanacions a través de visualitzacions
- Google: Anàlisi de cerques, de mapa (trànsit, recorreguts, estades...)
- Amazon: Compres
- Facebook:
- Ebay: Anàlisi de compres
- Spotify:

Exemple Volum + Velocitat:

- Manteniment predictiu: Predir el manteniment d'algun component.
- Gestió d'alarmes: Analitzar el procés d'algun component industrial i fer saltar l'alarma si falla. Per exemple si es filtren pèrdua de seguretat de arxius.
- Publicitat dirigida: Després de que una persona estigui comentant o buscant un cert producte, posar-li de seguida la publicitat encaminada.
- Detecció de frau: Analitzar quan un asseguraor surt rentable o no. Analitzar gent que gasta diners a on no toca perquè li han robat el compte o perquè està fent un comportament il·legal.

Variabilidad de datos

Estructurado. De bases de datos relacionales. Estructurados en tablas.

Desestructurado: Imágenes, Vídeos, Texto

Semi estructurado: Logs de un servidor. Formato JSON

**BIG DATA: Búsqueda de soluciones para almacenar y analizar datos (estructurados y no estructurados) de una manera económica, escalable y tolerante a fallos con el objetivo de descubrir información nueva y valiosa.**

**SIRVE PARA:**

- **Recopilar:** Big data facilita el paso para recopilar datos variados sin procesar (como registros, dispositivos móviles...) en tiempo real o por lotes.
- **Almacenar:** Big data proporciona un repositorio seguro, escalable y duradero donde almacenar datos antes y después de procesarlos.
- **Procesar y Analizar:** Procesar (clasificar, acumular, agregar...) datos para el consumo.
- **Consumir y Visualizar:** Consumir información visualizandola o inteligencia de negocio.

Ejemplos de tipos de procesos:

- Transformación técnica: Cambio formato, adaptación de los datos a una tecnología de uso.
- Transformación funcional. Aplicar una función a los datos: Filtrar, Agregar, Enriquezer

Ejemplos de tipos de análisis:

- Descriptivo. ¿Qué ha pasado y por qué? → Cuadro de mando
- Predictivo. ¿Probabilidad de que ocurra un evento? → Alertas, Fraude, Mantenimiento preventivo
- Prescriptivo. ¿Qué debería hacer si pasa x? → Sistemas de recomendación.

Sistemas tradicionales:

Escalado vertical.

<u>Sistemas tradicionales:</u>	<u>Sistema Distribuido Big Data</u>
<b>Escalado vertical</b> → Escalabilidad limitada - Ordenadores más grandes (más: rápidos, memoria, potentes...)	<b>Escalado horizontal</b> - Más ordenadores. Múltiples máquinas para un mismo trabajo. Sistema distribuido.  - Reto de complejidad de programación. Mantenimiento de dato y procesamiento en sincronía. ...
<b>Datos centralizados</b> - Procesar datos en durante una copia causa aumento del tiempo de copia. - Aumento de complejidad del mantenimiento. - Escalabilidad limitada.	<b>Datos distribuidos</b> en su almacenaje - Computación realizada en la subdivisión del dato.



- Datos distribuidos en su almacenado/ingesta.
- Procesos de computación en el lugar de su almacenaje.
- Hadoop se despliega sobre un conjunto de ordenadores (**clúster**) que trabajan de manera conjunta. Se despliega en servidores profesionales montados en un rack, ordenadores domésticos, raspberrys...
- Cada una de las máquinas que forman el clúster se conoce como **nodo**.
- Hadoop proporciona fiabilidad, disponibilidad, escalabilidad y tolerancia a fallos (si falla un nodo, el sistema sigue funcionando. Se reasignan las tareas a otros clústeres).

Frameworks principales:

- Map reduce (para batch)
- Apache Spark (batch y real time)

Características Batch:

- La información se vuelca periódicamente (cada min, hora, semana, mes...) en un clúster.
- El procesamiento no se realiza en el momento en el que el dato se genera en la fuente.
- La respuesta al procesamiento puede demorarse un tiempo.

Aplicaciones: Generación de reportes y cuadros de mandos, análisis de datos históricos...

Características Real time:

- La información se vuelca en un clúster en el tiempo en el que se genera en la fuente.
- El dato es procesado en el momento en que llega al sistema.
- La respuesta al procesamiento es practicante inmediata.

Aplicaciones: Sistemas de alertas, publicidad dirigida, IoT...

---

## Sistemas SQL y NOSQL

1. Introd al Big Data pag 55

### SQL:

- Permite integrar Bases de datos Relacionales con muchos sistemas a través de **driver** (elemento de comunicación a entre aplicaciones y bases de datos).

## Transaccional

- La transaccionalidad es una transformación que sigue las propiedades ACID
  - **Atomic**: “Todo o nada”
  - **Consistent**: Movimiento de datos de un estado a otro sin posibilidad de estados intermedios
  - **Isolated**: Cada transacción se ejecuta de manera individual sin posibilidad de mezclarse con las demás
  - **Durable**: Una vez la transacción se ejecuta con éxito, los cambios no se perderán y estarán disponibles para futuras transacciones

### Schema

1. Introd al Big Data pag 65

### New Vocabulary


**Framework (marco de trabajo)**: Un framework es una estructura o conjunto de herramientas que proporciona una base para el desarrollo de software. En el contexto de big data, un framework puede ser un conjunto de bibliotecas y herramientas que facilitan el procesamiento y análisis de grandes cantidades de datos, como Apache Hadoop o Apache Spark. Estos frameworks proporcionan una estructura y funcionalidades específicas para realizar tareas relacionadas con el big data.

**API (Interfaz de Programación de Aplicaciones)**: Una API es un conjunto de reglas y herramientas que permite a diferentes aplicaciones comunicarse entre sí. En el contexto de big data, una API podría ser un conjunto de funciones y procedimientos que permiten a los desarrolladores interactuar con un servicio o plataforma de almacenamiento de datos. Por ejemplo, una API de bases de datos podría permitir a una aplicación consultar y manipular datos almacenados.

**Driver**: Es un programa o componente que controla la coordinación en la ejecución de un programa distribuido. Por ejemplo, en Apache Spark, el driver es responsable de coordinar las tareas y de interactuar con el clúster para distribuir el trabajo entre los nodos.

**Nodo:** Es una máquina individual en un clúster. Puede haber nodos de almacenamiento, nodos de procesamiento y otros tipos de nodos. Los nodos trabajan en conjunto para realizar tareas de procesamiento y almacenamiento distribuido.

**Clúster:** Un clúster es un conjunto de nodos interconectados que trabajan juntos para procesar y almacenar grandes conjuntos de datos. Cada nodo en el clúster tiene sus propios recursos y capacidades, y el clúster en su conjunto ofrece una mayor potencia de procesamiento y almacenamiento que un sistema individual. En big data, los clústeres son esenciales para gestionar grandes volúmenes de datos de manera eficiente y escalable.



YARN (Yet Another Resource Negotiation)

MN = Manager.

MN Standby = Resource Manager que está apagado a la espera por si el Resource Manager principal cayese.

History Tracker: Registra los datos históricos de los procesos.

Client: Se conecta al Resource manager para mandarle un Job. Por ejemplo: Cuenta cuantas palabras hay en cada línea.

Ese Job está dividido por distintas tareas, Tasks. Hay dos tipos de Tasks: Map Task (siempre existe. Ejemplo: pasa una matriz de 1 y 0 para contar), Reduce Task (a veces no es necesario, aplica y suma el conteo).

MN Resource Manager: Administra los procesos de los distintos Worker Nodes dándoles las tareas concretas a realizar y administrando en caso de caída de alguno.

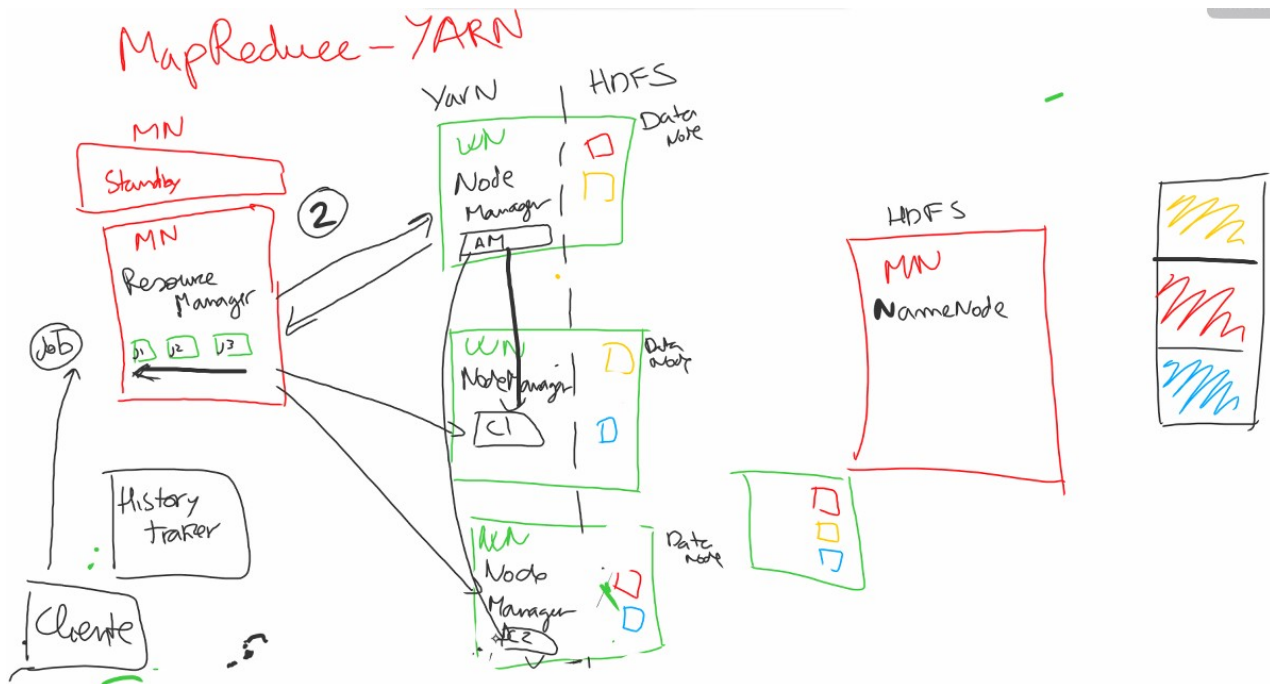
WN = Worker Nodes Slaves

Node Manager: Nodo de conexión con el manager (Resource manager)

Data Node: Nodo de conexión con los datos (Name Node. Es el nodo master de HDFS.)

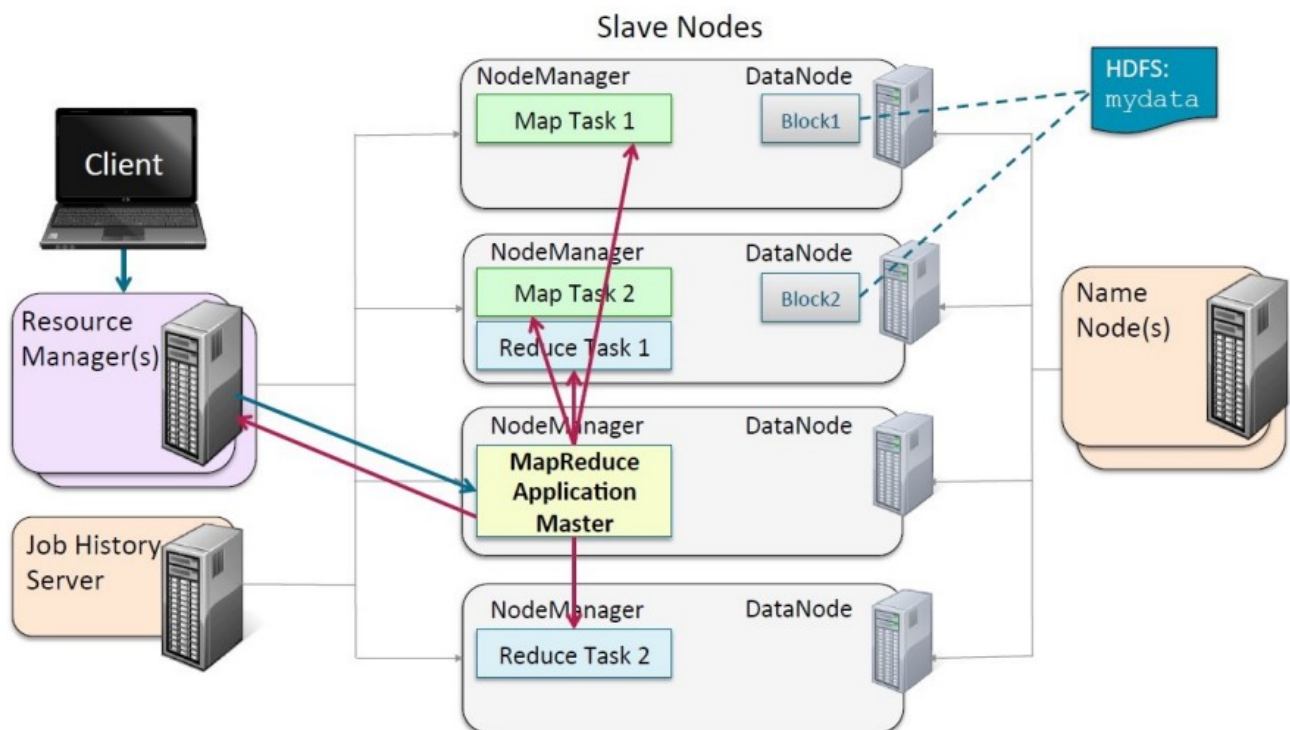
---

HDFS (Almacenamiento)




AM = Application Master: Hay un Worker Node Slave que actúa de comunicador principal (líder) de las órdenes del Resource Manager. Es un contenedor que está en el Node Manager del Worker Node Slave.

El Resource Manager se comunica con el Application Master diciéndole qué tipo de job es necesaria de lo que se deduce qué tipos de recursos que necesitarán. El Application Master consulta si tiene los recursos necesarios y le devuelve mensaje al Resource Manager y reparte las tareas.



Roles que pueden llegar a tener los Master Nodes.



## 2. Apache Hadoop. Diapo 80 6/3

Son “write once” porque así no hay que actualizar demasiadas veces las réplicas.

## Diapo 90 a 101 11/3

Formatos habituales.

Narrow → Dataset con pocas columnas.

Al escribir tenemos que saber si vamos a acceder mucho a los datos o no y saber las cantidades de datos que tenemos.

## Diapo 102. Mapreduce 11/3

MapReduce es Framework de Java (HDSF para procesar datos).

Características:

- Master Node administrará las tareas de manera automática.
- Todo hadoop de core y MapReduce está escrito en Java.
- El desarrollador solo se concentra en programar y se abstrae de las tareas de mantenimiento y administración del clúster.

Terminología

- Job → Ejecución completa de Mappers y Reducers.
- Task → Ejecución de Mapper o Reducceer.
- 

Fases:

1) Map

- Cada Map opera en un solo bloque de HDFS
- Se ejecuta en el nodo donde se almacena el bloque HDFS

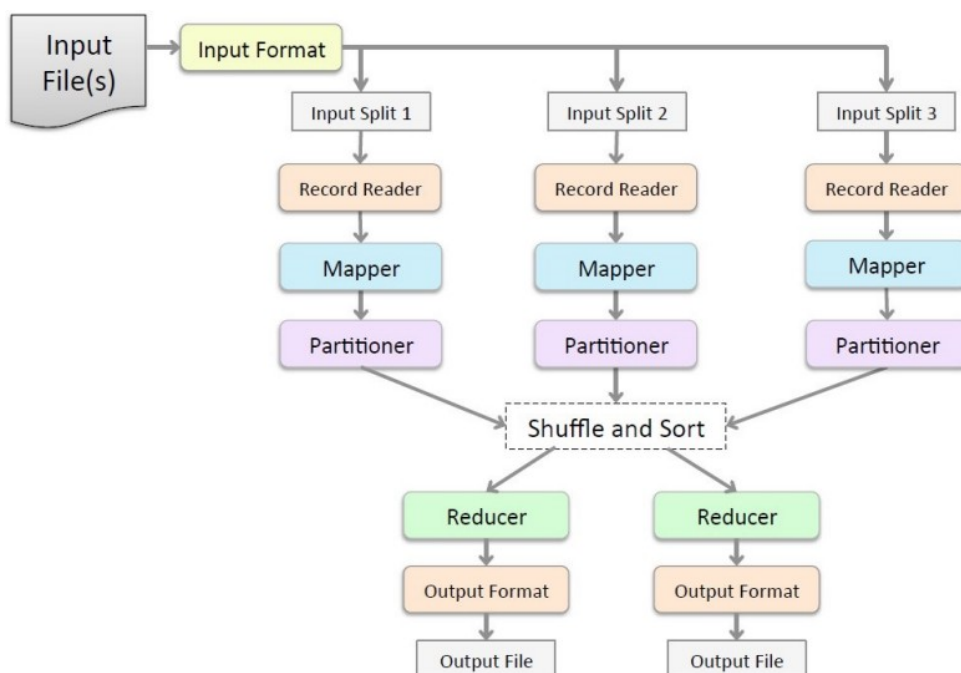
2) Shuffle and Sort

- Consolida y ordena los datos intermedios
- Se ejecuta después de terminar todos los Maps y justo antes de la fase de Reduce

3) Reduce

- Opera contra los datos que vienen de la fase Shuffle and Sort
- Proporciona la salida final





Per exemple: Compta d'aquest llistat de paraules quantes vegades es repeteix cada paraula. Els Mappers analitzen una part del text. Per cada paraula que troben li afageix un 1 al costat. Per exemple "hello11111" "you11" ... "hello1" "you111" ... "hello11" "you1"

Shuffle and Sort agafa les paraules i reparteix cada paraula al Reducer.

Després la Reducer ajunta tots els resultats de cada paraula i els suma.

Word Count

The cat sat on the mat  
The aardvark sat on the sofa

input file  
en HDFS  
input split

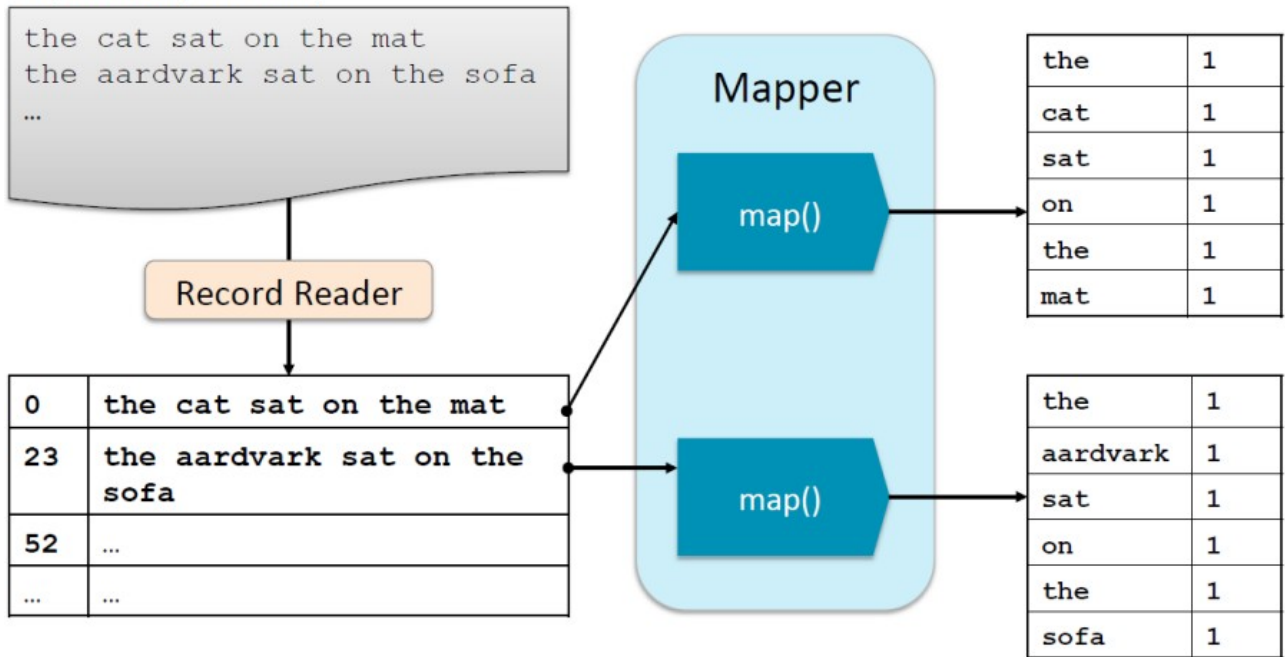
↳ RecordReader (K, V)

K	V
0	The cat... mat
23	The (...) sofa
53	→

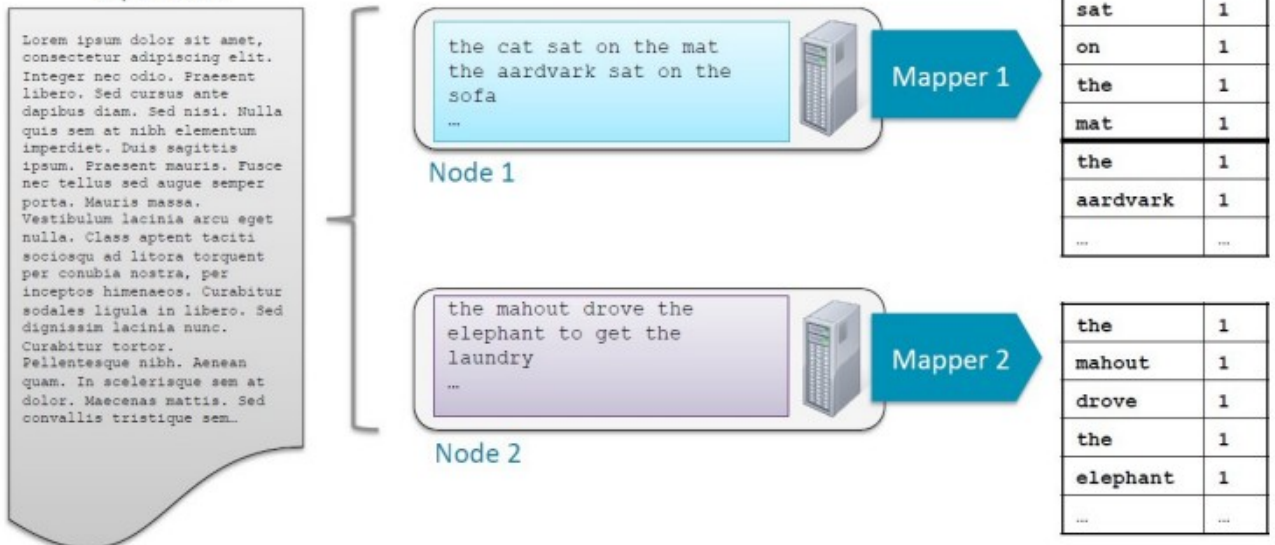
El key value es la cantidad de caracteres que contamos. 0 porque empezamos a leer en la "T" de "the cat sat on the mat". Y seguimos con el 23 porque seguimos en la "T" de "the aardvark sat on the sofa".

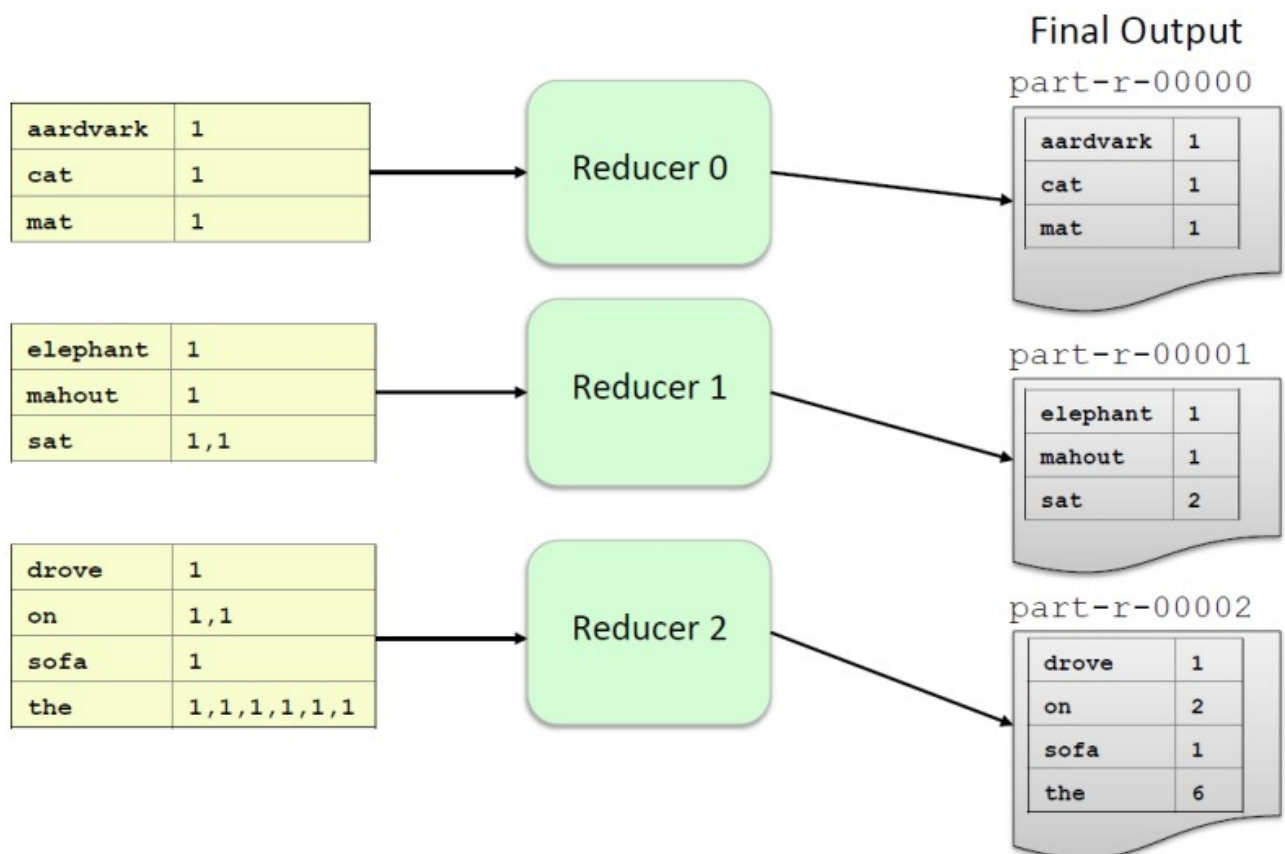
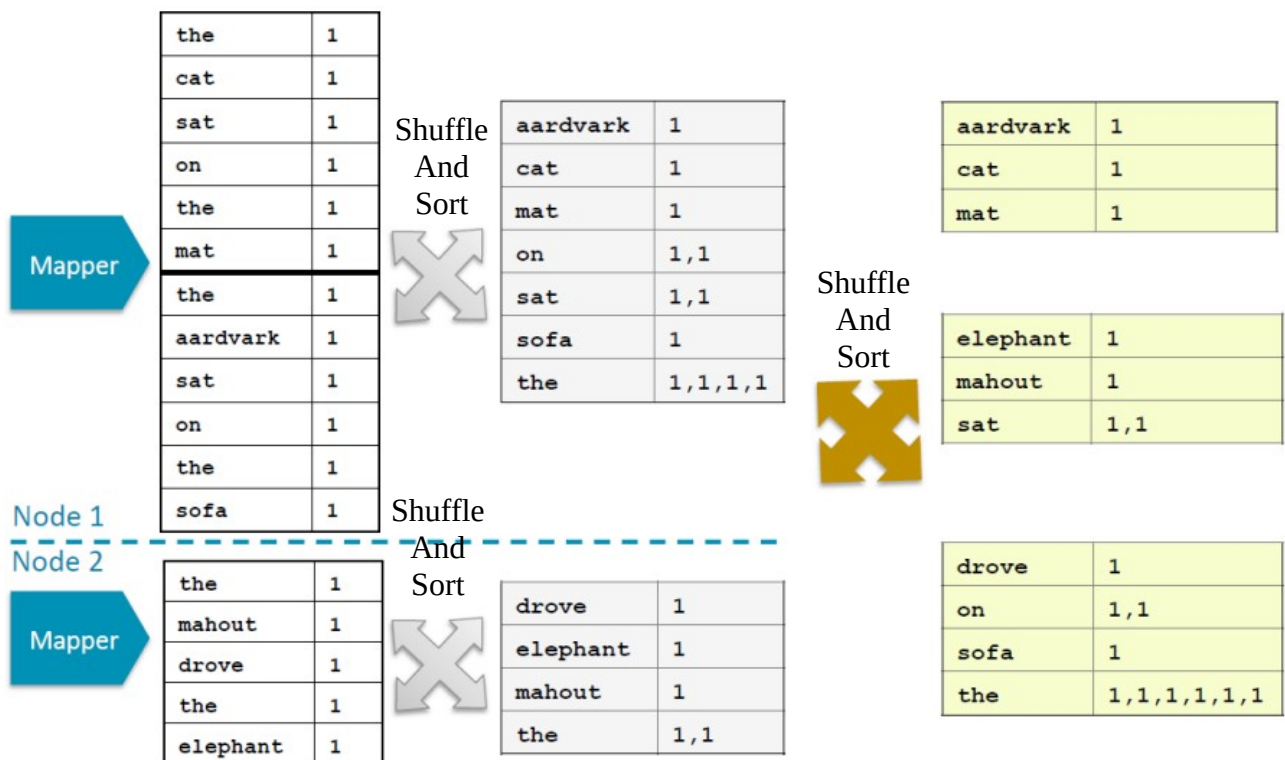


## Input Data (HDFS file)



## Input Data





### Hadoop Streaming API

Permite ejecutar jobs de map reduce con lenguajes diferentes a Java (Ruby, Python, Perl...)

- Ventajas:
  - No hace falta saber aprender Java.
  - Se pueden usar librerías propias de cada lenguaje.
- Desventajas:
  - Peor rendimiento.
  - Solo se puede tratar texto en el input de los jobs.

(diapo 58 a 63)

### Tool runner

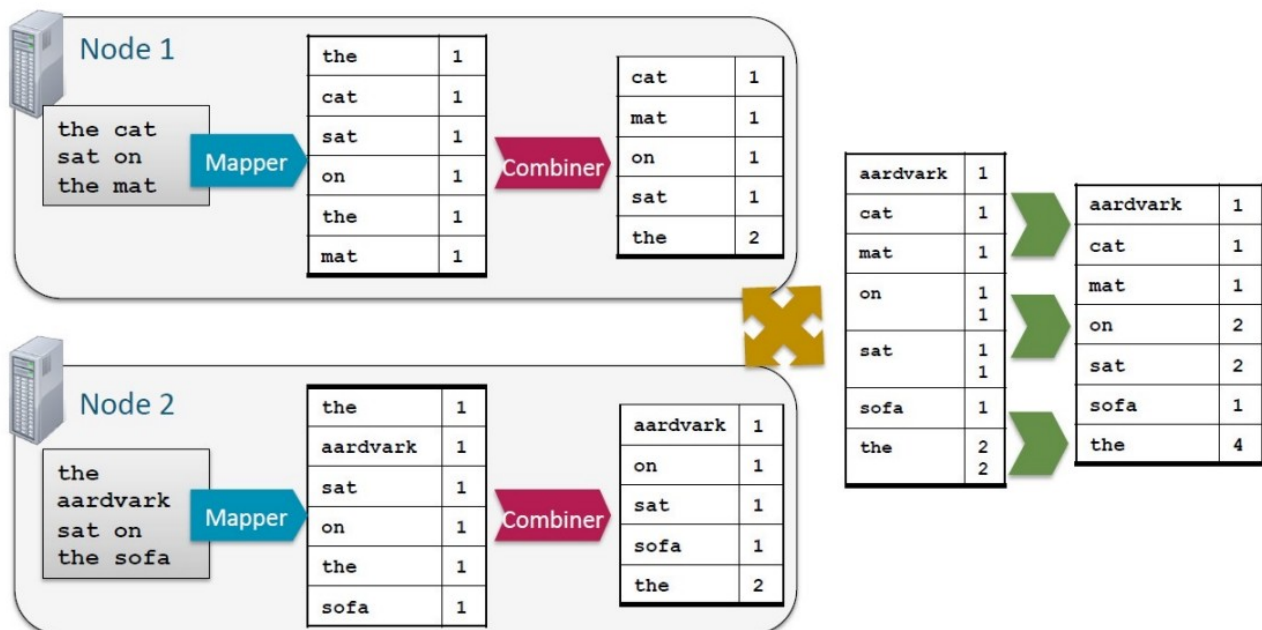
Permite especificar opciones en la línea de comandos.

(diapo 67 a 74)

### Combiners

Hace un paso intermedio entre el mapper y el reducer. Es como una reducción antes de hacer el reducer. Eso ayuda a que la cantidad de datos del mapper no sean tan grandes y produzcan demasiado trafico de red.

Ejemplo:




Vigilar porque los combiners no se pueden usar si las propiedades no son asociativas. Como por ejemplo hacer la media después de cada mapper no es lo mismo que hacer la media al final.

(diapo 80 a 89)

### Partitioner:

Determina en que reducer va cada key. Distribuye las key en los reducers.



Es importante que las mismas key vayan al mismo reducer para que lo cuente bien. Todos los “the” al particioner 0 por ejemplo.

10/4/24

Map reduce se encarga del procesado.

Yarn es el resource allocation.

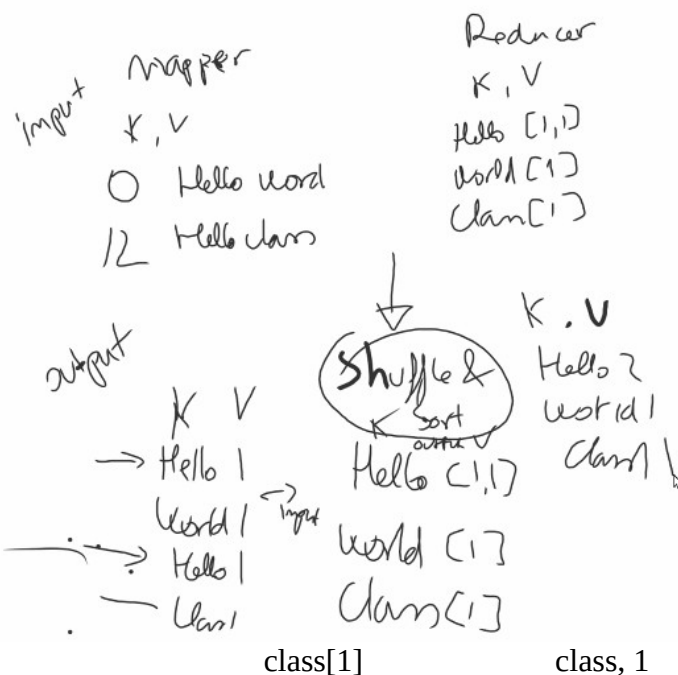
HDFS se encarga del almacenamiento.

<u>Word Count</u>	<u>Mapper</u>	<u>Shuffle and Sort</u>	<u>Reducer</u>
Hello world \n →	<b>Input:</b> K, V	<b>Input:</b> K, V	<b>Input:</b> K, V
Hello class \n	0, Hello world	Hello, 1	Hello [1,1]
	12, Hello class	world, 1 →	world [1]
	<b>Output:</b> K, V	Hello, 1	class[1]
	Hello, 1	class, 1	
	world, 1	<b>Output:</b> K, V	<b>Output:</b> K, V
	Hello, 1	Hello [1,1]	Hello, 2
	class, 1	world [1]	world, 1

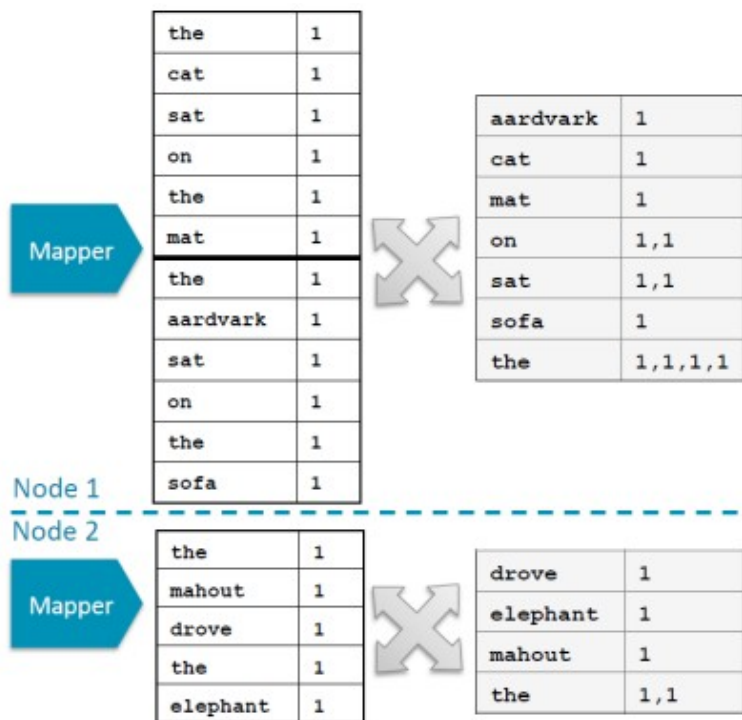
Word Count

```

Hello world \n
Hello class \n
  
```



El combiner seria:



Combiner 1:

Aardvark 1

Cat 1

Mat 1

Shuffle and Sort:

On 2

Aardvark [1,0]

Sat 2

Cat [1,0]

Mat [1,0]

On [2,0]

Sat [2,0]

Sofa [1,0]

The [4,2]

Drove [0,1]

Elephant [0,1]

Mahout [0,1]

Elephant 1

Mahout 1

The 2


Combiner 2:

Drove 1

Elephant 1

Mahout 1

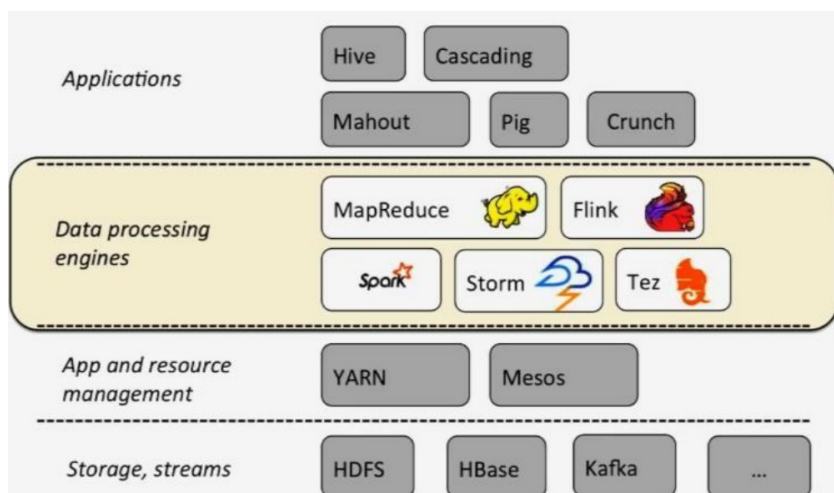
The 2



Spark puede usar su propio resource manager (resource allocation) o puede usar otros que sea del archivo de tipo que está usando.

Apache Spark

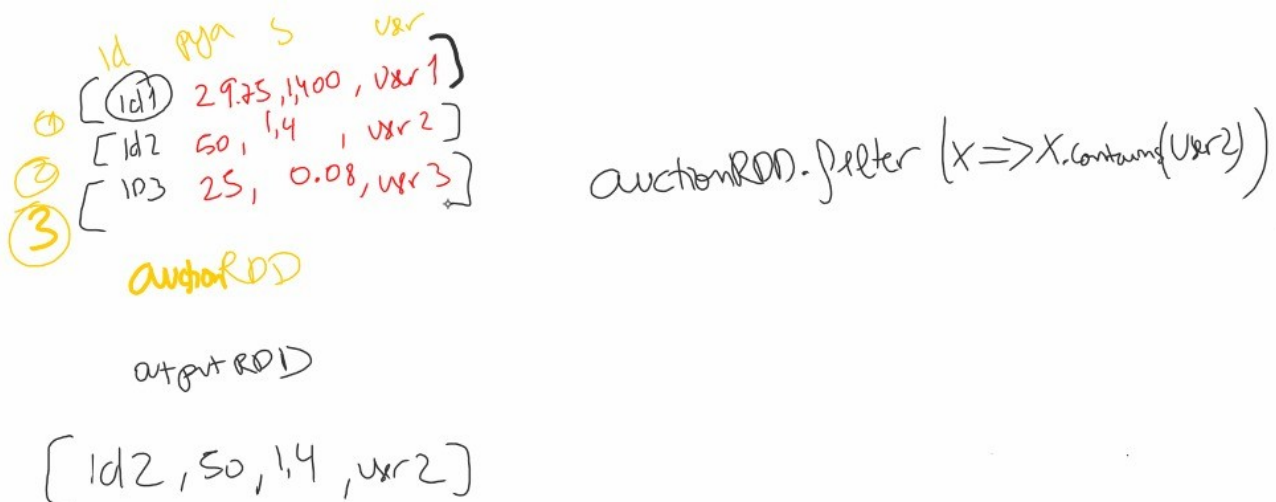
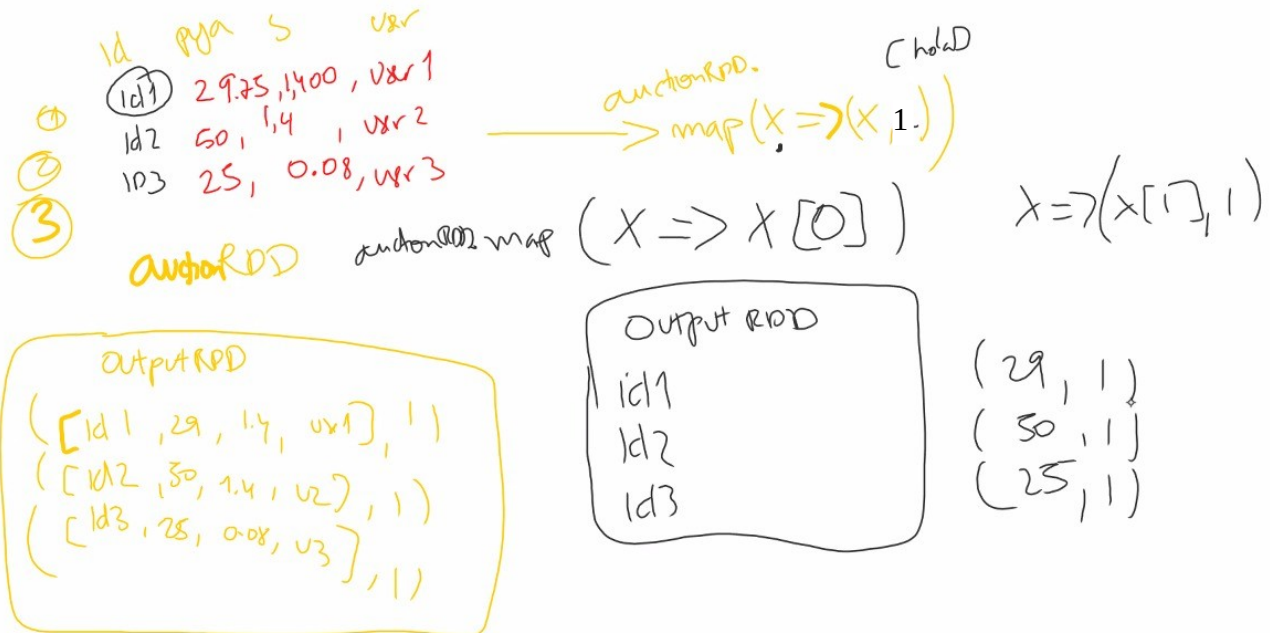
Plataforma para la computación distribuida en clúster, construida por encima de la capa de almacenamiento que extiende las funcionalidades de MapReduce con mas componentes: Streaming, Analítica Interactiva, SQL.



Contra disco → se guarda en HDFS

Contra memoria → se guarda en el nodo. Si se cuelga la info no se pierde porque lo ha guardado el "Graph" "DAG" que tiene los pasos de transformación de los datos guardados como una receta de cocina y al colgarse se sabe a que punto se estaba.

**RDD (Resilient Distributed Dataset). Transformaciones.** Devuelven un RDD





① 

id	price	user
1	29.75	usr1
2	50	usr2
3	25	usr3

  
 ②  
 ③

auctionRDD

outputRDD

auctionRDD.filter( $x \Rightarrow x.func(a)$ )

$x \Rightarrow x.func(a)$   
 func a ()  
 { if user 1 in  
 x[3] return x }

if usr 1 in  
 x[3]  
 return x

id	bid	user
1	50	A
2	60	B
3	70	C
3	80	A

auctionRDD

b = auctionRDD.map( $x \Rightarrow (x[0], 1)$ )

c = b.groupByKey()

b  
 (1, 1)  
 (2, 1)  
 (3, 1)  
 (3, 1)

(1, [1])  
 (2, [1])  
 (3, [1, 1])

id	bid	user
1	50	A
2	60	B
3	70	C
3	80	A

auctionRDD

b = auctionRDD.map( $x \Rightarrow (x[0], 1)$ )

c = b.reduceByKey( $(x, y) \Rightarrow x + y$ )

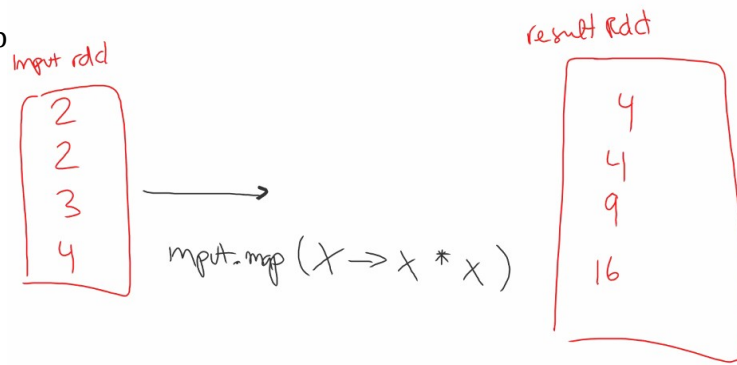
b  
 (1, 1)  
 (2, 1)  
 (3, 1)  
 (3, 1)

1, [1]  
 2, [1]  
 3, [1, 1]

?  
 C  
 1, [1]  
 2, [1]  
 3, [2]



## Transformación map



Pág 77 a 93. Apache Spark.


**RDD (Resilient Distributed Dataset). Acciones.** No devuelve una RDD

Las acciones se realizan una vez y no se guardan en memoria. Cada vez que se llama una acción, se empieza el proceso desde el principio.

Lazy Evaluated: No se realiza ninguna transformación hasta que no se realice antes una acción.

Por lo tanto, el siguiente **DAG** (Gráfico Acíclico Dirigido)

$r = i.map(x \rightarrow x * x)$   
 $r.persist()$   
 $r.count()$   
 $r.collect()$

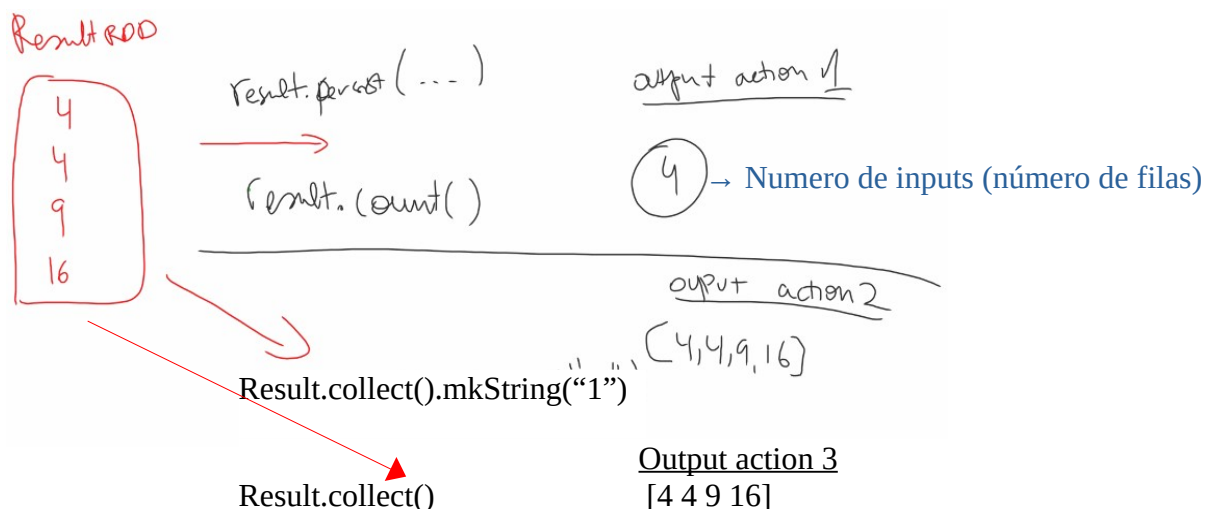


Lo que hace es:

- No ejecutar el map porque es una transformación.
- Hace el count (1)
- Hace el collect (2)

$r = i.map(x \rightarrow x * x)$   
 $r.persist()$   
 $r.count()$   
 $r.collect()$

Con [persist](#) → Guarda en el estado que está el cluster.



`Unpersist()` → Elimina los datos de la memoria de RDD

## reduce by key. Pair rdd.

## Transformaciones RDD. Pág 97 a 106 Apache Spark.

pairrdd = ( {1,2}, {3,4}, {3,6} )

→ Input

reduceByKey (función)

→ Agrupa por key. Las que tienen las mismas key, las agrupa.

pairrdd.reduceByKey ((x,y) → x+y)

→ Suma todos los valores de las mismas key

outputpairrdd = ( {1,2}, {3,10} )

→ Output

## groupByKey

pairrdd = ( {1,2}, {3,4}, {3,6} )

→ Input

pairrdd.groupByKey ()

outputpairrdd = ( {1,[2]}, {3,[4,6]} )

→ Output

## pair rdd. map values

pairrdd = ( {1,2}, {3,4}, {3,6} )

→ Input

→ Suma 1 a cada valor  
pairrdd.mapValues (v → v+1)

{1,3} {3,5} {3,7}

→ Output

## flat map values

{ (1,2), (3,4), (3,6) }

→ Input

~~flat~~ Map values (x → x to 5)

→ Coge cada valor y lo lleva hasta 5.

Por ejemplo la key 1 que tiene valor 2 lo repite hasta llegar a 5.

La key 3 que tiene valor 4 lo repite hasta llegar a 5

La key 3 que tiene valor 6, lo elimina ya que su valor es menor que 5

[ ]

2, 3, 4, 5  
4, 5

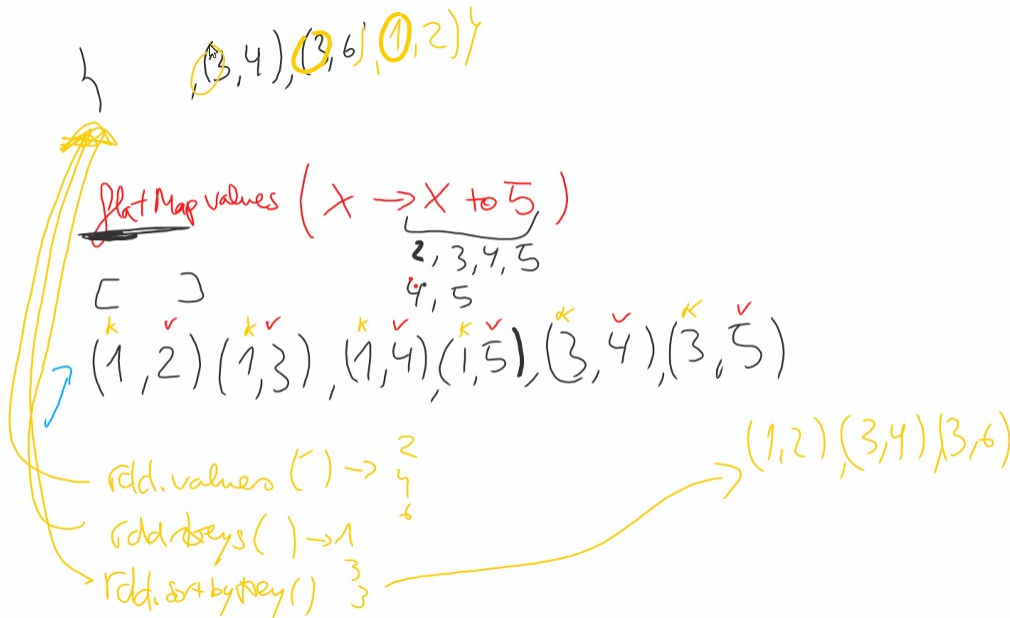
(1,2) (1,3) (1,4) (1,5) (3,4) (3,5)

Como es flat no devuelve listas.  
Devuelve tuplas.

→ Output

Para acceder a los valores podríamos hacer un map

`rdd.values ; rdd.keys ; rdd.sortbykey`



`rdd.subtractbykey`

rdd1 { (1,2), (3,4), (3,6) }  
rdd2 { (3,9) }

rdd1.subtractbykey(rdd2)  
output rdd { (1,2) }

→ De la rdd1 quita los que tengan la misma key que el rdd2

La rdd2 tiene key 3. De rdd1 se quitan todas las de la key3. (independientemente del value)

`rdd.join`

→ join es un inner join.

rdd1 { (1,2), (3,4), (3,6) }  
rdd2 { (3,9) }

De las keys que coinciden, se añade el valor de la 2ª key en las (key, value de la 1ª)

rdd1.join(rdd2)

Output rdd2 = (3, (4,9)), (3, (6,9))



### `rdd.rightouterjoin`

rdd1 { (1,2), (3,4), (3,6) }  
rdd2 { (3,9) }

Hay la key 3 con algunos 4 todo de nueves.

Hay la key 3 con algunos 6 y en todos hay 9

`Rdd1.rightouterjoin(rdd2)`

(3, (some(4), 9)),  
3, (some(6), 9))

### `rdd.rightouterjoin`

rdd1 { (1,2), (3,4), (3,6) }  
rdd2 { (3,9) }

Es lo mismo que hacer `rdd1.leftouterjoin(rdd2)`

`Rdd2.rightouterjoin(rdd1)`

(1, (2, none))  
(3, (4, some(9))  
(3, (6, some(9))

### `rdd.cogroup`

rdd1 { (1,2), (3,4), (3,6) }  
rdd2 { (3,9) }

→ En rdd1 que keys hay? De las key que haya escribe los valores de esa key en la rdd1 en una lista tuplada con otra lista de valores de esa key en el rdd2. O sea:

(key, ([valor 1 de esa key en rdd1, [valor 2 de esa key en rdd1], [valor que haya en el rdd2]))

`rdd1.cogroup(rdd2)`

(1, ([2], []))  
(3, ([4, 6], [9]))

`rdd.filter length`

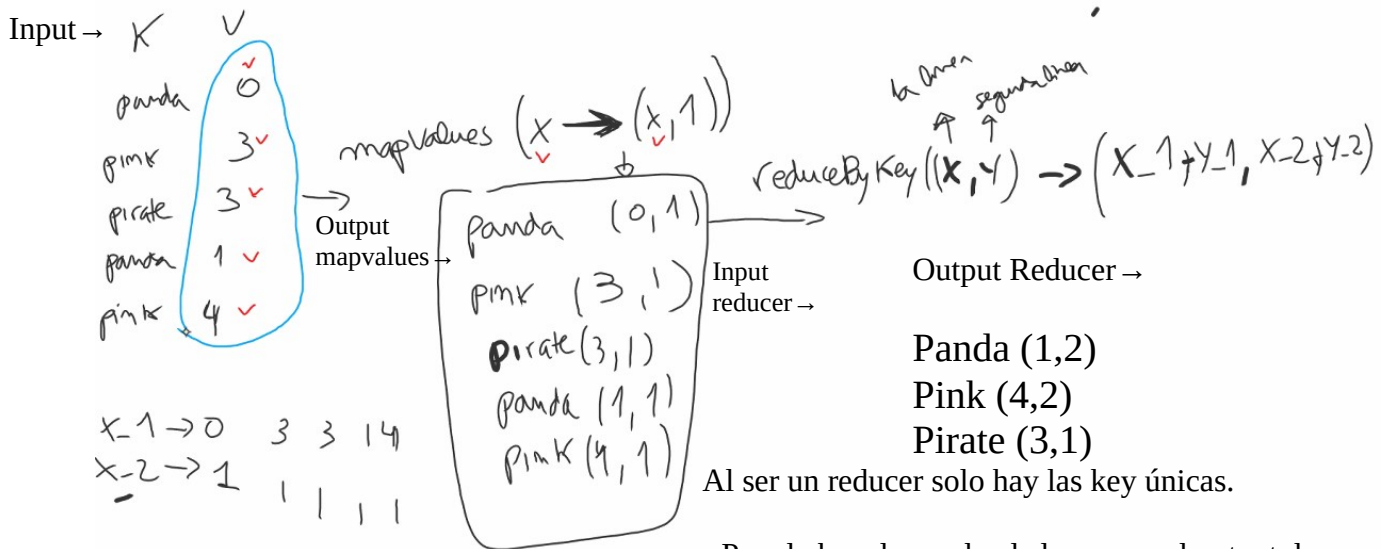
K	V
1	hola
2	sal
3	"123456"

`rdd.filter( Key, value ) → Value length > 4`

→ Devuelve las key y values en los que el tamaño de caracteres sea mayor a 4

(3 "123456")

`rdd.mapvalues rdd.reducebykey`



• Para la key de panda, dado que en el output de mapvalues hay panda(0,1) y panda(1,1) el resultado del reducer es sumar  $x_1 + y_1$ ,  $x_2 + y_2$  o sea: 0+1, 1+1

• Para la key de pink, dado que en el output de mapvalues hay pink(3,1) y pink(4,1) el resultado del reducer es sumar  $x_1 + y_1$ ,  $x_2 + y_2$  o sea: 3+1, 1+1

• Para la key de pirate, dado que en el output de mapvalues solo hay pirate(3,1) el resultado del reducer directamente eso: pirate(3,1)

batch duration  $\Rightarrow 1s$   
 window duration  $\Rightarrow 3s$   
 window slide frequency  $\Rightarrow 2s$

Batch duration = 1 segundo  
 Window duration = 3 segundos  
 Window slide frequency = 2 segundos

