# Máster en Big Data

Tecnologías de Almacenamiento

3. Hands-On: Ejecución MapReduce

## Índice

Introducción	.3
Eiecutando un Job	.3
•	7
E	ntroducción



### 1. Introducción

El objetivo de este Hands-On es aprender a ejecutar jobs de MapReduce por línea de comandos y entender su comportamiento. El entorno de ejecución será la máquina desplegada en el Hands-On anterior.

## 2. Ejecutando un Job

## Ejecución un MapReduce

Una vez las clases necesarias estén implementadas, se deben compilar

```
$ javac -classpath `hadoop classpath` MyMapper.java
MyReducer.java MyDriver.java
```

Empaquetarlas en un jar

```
$ jar cf MyMR.jar MyMapper.class MyReducer.class
MyDriver.class
```

• Y lanzar el job al clúster utilizando el comando siguiente

```
$ hadoop jar MyMR.jar MyDriver in_file out_dir
```

Todas las instrucciones deben introducirse mediante Shell de Linux.

- a) Ejecutar el job del proyecto WordCount ya compilado en la carpeta /home/training/training/Jars (la clase de entrada y su package es nextret.WordCount)
  - Usamos *cd* para salir de las carpetas. Usamos *ls* para listar lo que tenemos allí. Usmos *cd* + *nombre carpeta* para entrar en la carpeta.

```
[training@localhost ~]$ cd
[training@localhost ~]$ cd
[training@localhost ~]$ ls
Desktop Documents Downloads eclipse kiji-bento-albacore-1.0.5-release.tar.gz
lib Music Pictures Public ruta scripts park=1.30 src Templates
```

training training\_materials Videos workspace workspace.save.dev

[training@localhost ~]\$ cd training
[training@localhost training]\$ ls

Jars
[training@localhost training]\$ cd Jars
[training@localhost Jars]\$ ls
wordcount.jar

De este modo en el siguiente paso no hace falta poner la ruta.

• Ejecutamos el proyecto wordcount.jar. Para hacerlo usamos el siguiente esquema

\$ hadoop jar MyMR.jar MyDriver in\_file out\_dir

#### Donde:

- MyMR es el jar con su path. En nuestro caso como ya estamos en el directorio no hace falta poner el path.
- MyDriver es nextret.WordCount
- In file son los datos a leer. En este caso leemos el texto de Shakespeare
- Out\_dir es el directorio de salida. Tiene que ser uno que no exista, como por ejemplo una carpeta llamada "Output" dentro de traning.

#### Vemos:

[training@localhost Jars]\$ hadoop jar wordcount.jar nextret.WordCount /user/training/Shakespeare /user/training/Output

Como respuesta obtenemos:



```
24/03/13 14:59:56 WARN mapred.JobClient: Use GenericOptionsParser for parsing the arguments. Applications should impl
ement Tool for the same.
24/03/13 14:59:56 INFO input.FileInputFormat: Total input paths to process : 5
24/03/13 14:59:56 INFO mapred.JobClient: Running job: job_202403111456_0003
24/03/13 14:59:57 INFO mapred.JobClient: map 0% reduce 0%
24/03/13 15:00:04 INFO mapred.JobClient: map 40% reduce 0%
                                          map 80% reduce 0%
24/03/13 15:00:09 INFO mapred.JobClient:
24/03/13 15:00:10 INFO mapred.JobClient: map 100% reduce 0%
24/03/13 15:00:13 INFO mapred.JobClient: map 100% reduce 100%
24/03/13 15:00:13 INFO mapred.JobClient: Job complete: job_202403111456_0003
24/03/13 15:00:13 INFO mapred.JobClient: Counters: 32
                                           File System Counters
24/03/13 15:00:13 INFO mapred.JobClient:
24/03/13 15:00:13 INFO mapred.JobClient:
                                             FILE: Number of bytes read=20983046
24/03/13 15:00:13 INFO mapred.JobClient:
                                             FILE: Number of bytes written=32957704
                                             FILE: Number of read operations=0
24/03/13 15:00:13 INFO mapred.JobClient:
24/03/13 15:00:13 INFO mapred.JobClient:
                                             FILE: Number of large read operations=0
24/03/13 15:00:13 INFO mapred.JobClient:
                                             FILE: Number of write operations=0
                                             HDFS: Number of bytes read=5343801
24/03/13 15:00:13 INFO mapred.JobClient:
                                             HDFS: Number of bytes written=324841
24/03/13 15:00:13 INFO mapred.JobClient:
                                             HDFS: Number of read operations=10
24/03/13 15:00:13 INFO mapred.JobClient:
                                             HDFS: Number of large read operations=0
24/03/13 15:00:13 INFO mapred.JobClient:
24/03/13 15:00:13 INFO mapred.JobClient:
                                             HDFS: Number of write operations=1
24/03/13 15:00:13 INFO mapred.JobClient:
                                           Job Counters
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Launched map tasks=5
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Launched reduce tasks=1
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Data-local map tasks=5
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Total time spent by all maps in occupied slots (ms)=22382
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Total time spent by all reduces in occupied slots (ms)=9222
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Total time spent by all maps waiting after reserving slots (ms)=0
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Total time spent by all reduces waiting after reserving slots (ms)=0
24/03/13 15:00:13 INFO mapred.JobClient:
                                           Map-Reduce Framework
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Map input records=175558
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Map output records=974078
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Map output bytes=8880434
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Input split bytes=594
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Combine input records=0
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Combine output records=0
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Reduce input groups=31809
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Reduce shuffle bytes=10828620
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Reduce input records=974078
                                             Reduce output records=31809
24/03/13 15:00:13 INFO mapred.JobClient:
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Spilled Records=2862397
24/03/13 15:00:13 INFO mapred.JobClient:
                                             CPU time spent (ms)=4770
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Physical memory (bytes) snapshot=1092792320
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Virtual memory (bytes) snapshot=4343140352
24/03/13 15:00:13 INFO mapred.JobClient:
                                             Total committed heap usage (bytes)=689524736
[training@localhost Jars]$
```

#### b) Revisa los archivos generados y visualiza los resultados. Explica los resultados.

#### - Visitamos la nube para ver si se creó la carpeta Output.

#### -Vemos lo que hay dentro de la carpeta.

—Dentro de la carpeta *logs* hay otra carpeta *history* 

```
[training@localhost training]$ hadoop fs -ls /user/training/Output/_logs
Found 1 items
drwxr-xr-x - training supergroup 0 2024-03-13 14:59 /user/training/Output/_logs/history
```

- Dentro de la carpeta history hay 2 archivos.

#### Entonces explicamos esquemáticamente lo que hay en Output

- Archivo \_SUCCESS que no tiene peso. Simplemente es un archivo que indica que se ha realizado correctamente la ejecución.
- Carpeta \_logs.
  - Carpeta history
    - o Archivo job 202403111456 0003 1710356396754 training Word+Count
    - o Archivo job 202403111456 0003 conf.xml
- Archivo part-r-00000.

Leemos lo que hay en el archivo part-r-00000

[training@localhost training]\$ hadoop fs -cat /user/training/Output/part-r-00000

Y la respuesta es muy larga (1400 páginas de Word) así que reducimos a las últimas palabras.

[training@localhost training]\$ hadoop fs -cat /user/training/Output/part-r-00000 | tail -n20

```
yourself
                  281
yourselves
                  74
youth
         288
youthful
                  32
youths
        5
zanies
         1
         1
zany
zeal
zealous 6
zeals
         1
zed
         1
zenith
zephyrs 1
zir
         2
         1
zodiac
         1
zodiacs 1
zone
         3
zounds
zwaggered
                  1
```

Tenemos el conteo de cada palabra. Key, tab, conteo.



c) Vuelve a ejecutar el mismo comando para ejecutar el Job, ¿qué ha pasado?

Volvemos a hacer los comandos anteriores y la respuesta es que "FileAlreadyEsistsExemption: Output already exists." Porque ya existe la carpeta "Output" que acabamos de crear.

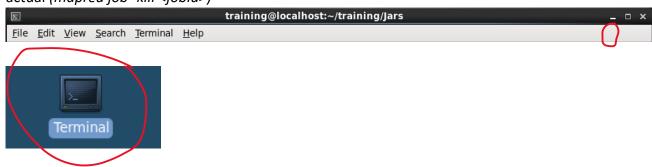
```
| Itraining@localhost risining|s cd | Itraining@localhost | 15 cd | Itraining@localhost | Itraining@loca
```

d) Elimina todos los archivos de esta última ejecución

Eliminamos y vemos que ya no aparece la carpeta "Output" en ese path.

#### 3. Finalizando un Job

a) Abre dos terminales de Linux. En uno, vuelve a ejecutar el Job con el volcado del resultado en un nuevo directorio. En el otro, lista los Jobs en ejecución (mapred job -list) y mata el Job actual (mapred job -kill <jobld>)



En una consola preparamos el siguiente comando:

[training@localhost Jars]\$ hadoop jar wordcount.jar nextret.WordCount /user/training/Shakespeare /user/training/Output

En otra consola de preparamos "mapred job". Primero ejecutamos lo anterior y después este :

[training@localhost ~]\$ mapred job -list

#### Que devuelve

```
l jobs currently running
JobId State StartTime UserName Priority SchedulingInfo
job 202403111456 0008 4 1710359015824 training NORMAL NA
```

#### Y de forma rápida (antes que termine) escribimos:

```
[training@localhost ~]$ mapred job -kill job 202403111456 0008
```

Donde el número de job es el que ha devuelto anteriormente. Para hacerlo exitosamente nos damos cuenta que solo cambia el valor final de 005 a 006 a 007 para cada jo basí que tenemos preparado previamente el comando y con solo  $\uparrow$  ya lo tenemos escrito.

#### La respuesta en la consola donde lo matamos es:

```
killed job job 202403111456 0008
```

#### La respuesta donde se está ejecutando el job es:

```
|24/03/13 15:43:35 WARN mapred.JobClient: Use GenericOptionsParser for parsing the arguments. Applications should implement Tool for t
he same.
24/03/13 15:43:35 INFO input.FileInputFormat: Total input paths to process : 5
24/03/13 15:43:35 INFO mapred.JobClient: Running job: job 202403111456_0008
24/03/13 15:43:36 INFO mapred.JobClient: map 0% reduce 0%
24/03/13 15:43:42 INFO mapred.JobClient: Job complete: job_202403111456_0008
24/03/13 15:43:42 INFO mapred.JobClient: Counters: 6
24/03/13 15:43:42 INFO mapred.JobClient:
                                             Job Counters
24/03/13 15:43:42 INFO mapred.JobClient:
                                                Launched map tasks=2
24/03/13 15:43:42 INFO mapred.JobClient:
                                                Data-local map tasks=2
24/03/13 15:43:42 INFO mapred.JobClient:
                                                Total time spent by all maps in occupied slots (ms)=7760
                                                Total time spent by all reduces in occupied slots (ms)=1192
24/03/13 15:43:42 INFO mapred.JobClient:
24/03/13 15:43:42 INFO mapred.JobClient:
                                                Total time spent by all maps waiting after reserving slots (ms)=0
```

