Máster en Big Data

Tecnologías de Almacenamiento

8. Hands-On: Desarrollo Apache Spark SQL

Presentado por: José David Angulo y Albert Ripoll



Índice

1.	Introducción	3
2.	Entorno	3
3.	Creación del DataFrame	3
4.	Inspección de datos	7

1. Introducción

El objetivo de este Hands-On es el de familiarizarse con una de las librerías más populares del framework de Spark como es SparkSQL

2. Entorno

Para la realización de los ejercicios se va a utilizar *spark-shell* en scala ya que nos proporciona un entorno muy dinámico para la introducción de funciones y nos permite recibir una respuesta inmediata.

Para ello, utilizaremos la máquina virtual desplegada en Hands-On anteriores llamada Developer_Hadoop y ejecutaremos el Spark Shell ubicado en /home/training/spark-1.3.1/bin

El dataset que utilizaremos se llama auctiondata.csv y está ubicado en /home/training/training materials/developer/data/auction.csv

3. Creación del DataFrame

a) Crear el SQL Context

val sqlContext = new

org.apache.spark.sql.SQLContext(sc)



b) Realiza el import correspondiente para convertir un RDD en un DataFrame

import sqlContext.implicits._





c) Definición del esquema usando una case class

case class

Auction(auctionid:String,bid:Float,bidtime:Float,bidder:String,bidderrate:Int,openbid:Float,finprice:

Float, itemtype: String, dtl:Int)



d) Crea un RDD llamado *inputRDD* para cargar el *auctiondata.csv*. Asegurate de dividir el archivo de entrada con el separador ","

e) Ahora Mapea el inputRDD a case class

val auctions = inputRDD.map

(a => Auction(a(0), a(1), toFloat, a(2), toFloat, a(3), a(4), toInt, a(5), toFloat, a(6), toFloat, a(7), a(8), toInt))

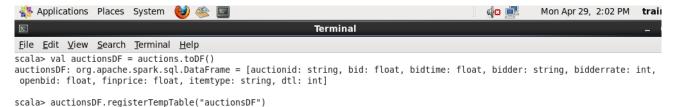




f) Convierte el RDD resultante del punto anterior en un *DataFrame* llamado *auctionsDF* y regístralo como una tabla (Registrandolo de esta manera, podremos ejecutar consultas SQL usando los métodos proporcionados por sqlContext)

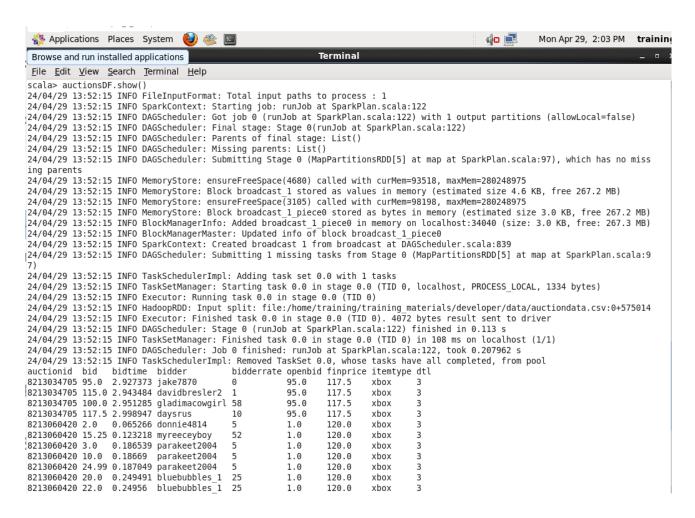
val auctionsDF = auctions.toDF()

auctionsDF.registerTempTable("auctionsDF")



g) ¿Que acción puedes hacer para comprobar los datos en el DataFrame?

auctionsDF.show()



h) ¿Que función del DataFrame puedes utilizar para ver el esquema del mismo?

auctionsDF.printSchema()

```
scala> auctionsDF.printSchema()
root
 |-- auctionid: string (nullable = true)
 |-- bid: float (nullable = false)
 |-- bidtime: float (nullable = false)
 |-- bidder: string (nullable = true)
 |-- bidderrate: integer (nullable = false)
 |-- openbid: float (nullable = false)
 |-- finprice: float (nullable = false)
 |-- itemtype: string (nullable = true)
 |-- dtl: integer (nullable = false)
```

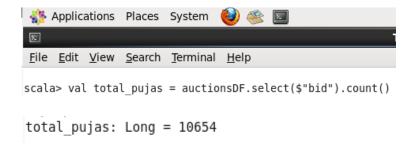


4. Inspección de datos

a) ¿Cuál es el número total de pujas?

val total_pujas = auctionsDF.select(\$"bid").count()

Respuesta: 10654



b) ¿Cuál es el número total de subastas distintas?

Hay 20 subastas distintes. El siguiente código nos muestra cuantas pujas hay en cada subasta y se pueden contar 20 líneas.

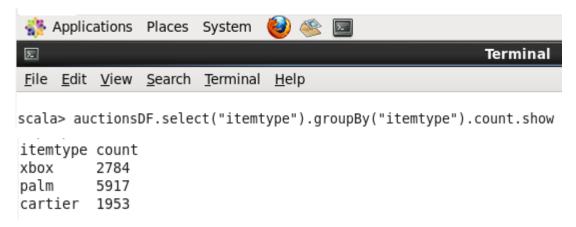
auctionsDF.select("auctionid").groupBy("auctionid").count.show



```
auctionid count
3016384507 26
3024487267 33
3022000145 3
(3024953755 20
8214435808 2
8214864154 12
8212668731 36
3024307014 6
3024680777 3
3020684186 27
3016651485 20
3020329965 29
3025507248 7
3020237085 18
8214803514 13
1644357387 25
3023639316 31
3023251181 24
3015053536 16
1644077820 11
scala>
```

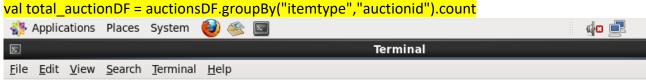
c) ¿Cuál es el número de objetos distintos?

Hay 3 objetos distintos. Xbox, Palm, Cartier. El siguiente código nos muestra cuantas pujas hay en cada objeto y se pueden contar 3 líneas.



d) Queremos contar el número de pujas por subasta y tipo de objeto (como se muestra a continuación). ¿Como se podría hacer? (pista: usar groupBy)

itemtype	aucid	count
palm	3019326300	10
xbox	8213060420	22
palm	3024471745	5
xbox	8213932495	9
cartier	1646573469	15
palm	3014834982	20
palm	3025885755	7
palm	3016427640	19
xbox	8214435010	35
cartier	1642185637	9



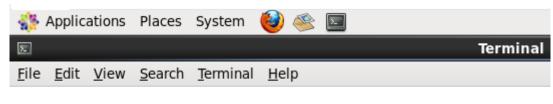
scala> val total_auctionDF = auctionsDF.groupBy("itemtype","auctionid").count
total auctionDF: org.apache.spark.sql.DataFrame = [itemtype: string, auctionid: string, count: bigint]

e) y f) Por cada elemento subastado y tipo, calcular el máximo, mínimo y la media de pujas. (pista: utilizar *groupBy* y *agg*)

a. Minima puja



auctionsDF.groupBy("itemtype","auctionid").min("bid").show()

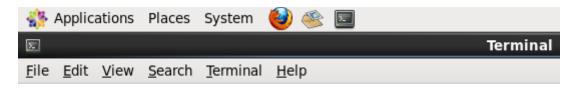


scala> auctionsDF.groupBy("itemtype","auctionid").min("bid").show()

```
itemtype auctionid MIN(bid)
palm
         3019326300 100.0
xbox
         8213060420 2.0
palm
         3024471745 180.0
xbox
         8213932495 100.0
         1646573469 35.0
cartier
palm
         3014834982 3.0
palm
         3025885755 180.0
         3016427640 100.01
palm
xbox
         8214435010 1.04
cartier
         1642185637 305.0
xbox
         8213073509 1.25
palm
         3015467305 10.0
cartier 1644138548 525.0
         3014527296 20.0
palm
cartier
         1640179146 50.0
palm
         3022668008 185.0
         3025656717 200.0
palm
palm
         3023700043 80.0
xbox
         8213085879 10.0
cartier 1639425502 222.0
```

b. Maxima puja

auctionsDF.groupBy("itemtype","auctionid").max("bid").show()

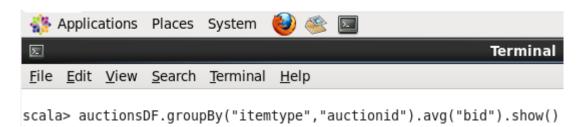


scala> auctionsDF.groupBy("itemtype","auctionid").max("bid").show()

```
itemtype auctionid MAX(bid)
palm
         3019326300 207.5
xbox
         8213060420 120.0
palm
         3024471745 202.49
xbox
         8213932495 127.5
cartier
         1646573469 1226.0
palm
         3014834982 217.5
         3025885755 203.5
palm
palm
         3016427640 245.0
xbox
         8214435010 122.5
         1642185637 510.0
cartier
xbox
         8213073509 114.5
         3015467305 227.5
palm
         1644138548 2100.0
cartier
palm
         3014527296 253.0
         1640179146 455.0
cartier
palm
         3022668008 210.1
palm
         3025656717 224.01
palm
         3023700043 228.01
xbox
         8213085879 96.0
cartier 1639425502 224.5
```

c. Puja media

auctionsDF.groupBy("itemtype","auctionid").avg("bid").show()



```
itemtype auctionid AVG(bid)
         3019326300 155.3490005493164
palm
xbox
         8213060420 66.4881818077781
palm
         3024471745 191.49600219726562
         8213932495 114.2222222222223
xbox
         1646573469 800.666666666666
cartier
         3014834982 96.1745002746582
palm
         3025885755 192.5
palm
palm
         3016427640 178.36999993575247
         8214435010 42.800571305411204
xbox
cartier
         1642185637 402.2222222222223
         8213073509 68.06904747372582
xbox
palm
         3015467305 129.2449986775716
cartier
         1644138548 1343.4761904761904
palm
         3014527296 124.1585715157645
         1640179146 303.0427259965376
cartier
palm
         3022668008 201.02000122070314
         3025656717 215.58999633789062
palm
palm
         3023700043 168.7290899103338
         8213085879 60.67000020345052
xbox
cartier 1639425502 223.25
```

g) ¿Cuál es el número de subastas cuyo precio es superior a 200?

Hay 212 subastas cuyo precio es mayor a 200.

auctionsDF.select("finprice").distinct.filter(auctionsDF("finprice")>200).count

Applications Places System

Terminal

File Edit View Search Terminal Help

scala> auctionsDF.select("finprice").distinct.filter(auctionsDF("finprice")>200).count 24/04/29 15:21:23 INFO ContextCleaner: Cleaned shuffle 9

res26: Long = 212 scala> ■

h) Queremos ejecutar algunos comandos básicos sobre todas las subastas que tienen un elemento del tipo "xbox". Es decir, queremos asilar en un nuevo dataframe con datos de los artículos "xbox" ¿Qué manera tenemos de hacer esto?

(pista: al tener registrado el DataFrame como una tabla podemos usar sentencias sql, el resultado será un nuevo DataFrame donde podremos aplicar acciones sobre el)

val TOTAL_xboxDF = sqlContext.sql("select * from auctionsDF where itemtype = 'xbox'")

TOTAL xboxDF.registerTempTable(TOTAL xboxDF") TOTAL xboxDF.show() Applications Places System **(2)** Tue Apr 30, 12:10 PM train Terminal File Edit View Search Terminal Help scala> val TOTAL_xboxDF = sqlContext.sql("select * from auctionsDF where itemtype = 'xbox'") TOTAL_xboxDF: org.apache.spark.sql.DataFrame = [auctionid: string, bid: float, bidtime: float, bidder: string, bidderrate: int, openbid: float, finprice: float, itemtype: string, dtl: int] Toeveloper_Hadoop - VMware Workstation 17 Player (Non-commercial use on Player ▼ | | | ▼ 🖧 🗀 农 Applications Places System scala> TOTAL_xboxDF.registerTempTable("TOTAL_xboxDF") scala> TOTAL xboxDF.show() bidderrate openbid finprice itemtype dtl auctionid bid bidtime bidder 8213034705 95.0 2.927373 jake7870 Θ 95.0 117.5 xbox 3 3 1 95.0 117.5 8213034705 115.0 2.943484 davidbresler2 xbox 58 95.0 117.5 xbox 3 8213034705 100.0 2.951285 gladimacowgirl 8213034705 117.5 2.998947 daysrus 95.0 117.5 xbox 3 10 8213060420 2.0 0.065266 donnie4814 5 1.0 120.0 xbox 3 3 8213060420 15.25 0.123218 myreeceyboy 52 1.0 120.0 xbox 3 8213060420 3.0 0.186539 parakeet2004 5 1.0 120.0 xbox 8213060420 10.0 0.18669 5 1.0 120.0 xbox 3 parakeet2004 3 5 120.0 8213060420 24.99 0.187049 parakeet2004 1.0 xbox 8213060420 20.0 0.249491 bluebubbles 1 25 1.0 120.0 xbox 3 3 1.0 8213060420 22.0 0.24956 bluebubbles 1 25 120.0 xbox 8213060420 24.0 0.249653 bluebubbles 1 25 1.0 120.0 xbox 3 3 8213060420 26.0 0.249757 bluebubbles 1 25 1.0 120.0 xbox 3 8213060420 80.0 0.59059 sa4741 3 1.0 120.0 xbox 51 3 8213060420 75.0 0.657384 jhnsn2273 1.0 120.0 xbox 8213060420 85.0 0.657917 jhnsn2273 51 1.0 120.0 xbox 3 8213060420 83.0 xbox 0.816447 sa4741 3 1.0 120.0 3 8213060420 100.0 1.005903 sa4741 3 3 1.0 120.0 xbox 8213060420 100.0 1.012697 jhnsn2273 51 1.0 120.0 xbox 3 3 8213060420 110.0 1.013056 jhnsn2273 51 1.0 120.0 xbox scala> TOTAL xboxDF.printSchema() root |-- auctionid: string (nullable = true) |-- bid: float (nullable = false) |-- bidtime: float (nullable = false) |-- bidder: string (nullable = true) -- bidderrate: integer (nullable = false) |-- openbid: float (nullable = false) |-- finprice: float (nullable = false) |-- itemtype: string (nullable = true) -- dtl: integer (nullable = false)

val comandos_xboxDF = sqlContext.sql("select * from TOTAL_xboxDF where bid>100")

comandos_xboxDF.show()



scala> val comandos_xboxDF = sqlContext.sql("select * from TOTAL_xboxDF where bid>100")
comandos_xboxDF: org.apache.spark.sql.DataFrame = [auctionid: string, bid: float, bidtime: float, bidder: string, bidderrate: in
t, openbid: float, finprice: float, itemtype: string, dtl: int]

scala> comandos xboxDF.show()

	623	La dela del	6244					J. 1
auctionid	bid	bidtime		bidderrate				
8213034705	115.0	2.943484	davidbresler2	1	95.0	117.5	xbox	3
8213034705	117.5	2.998947	daysrus	10	95.0	117.5	xbox	3
8213060420	110.0	1.013056	jhnsn2273	51	1.0	120.0	xbox	3
8213060420	105.0	2.79934	pagep123	2	1.0	120.0	xbox	3
8213060420	110.0	2.799676	pagep123	2	1.0	120.0	xbox	3
8213060420	115.0	2.800197	pagep123	2	1.0	120.0	xbox	3
8213060420	115.0	2.968495	skcardina	1	1.0	120.0	xbox	3
8213060420	117.5	2.972766	skcardina	1	1.0	120.0	xbox	3
8213060420	120.0	2.999722	djnoeproductions	17	1.0	120.0	xbox	3
8213067838	120.0	2.946516		Θ	29.99	132.5	xbox	3
8213067838	105.0	2.989051	unique82me	Θ	29.99	132.5	xbox	3
8213067838	110.0	2.989178	unique82me	Θ	29.99	132.5	xbox	3
8213067838	115.0	2.989317	unique82me	Θ	29.99	132.5	xbox	3
8213067838	120.0	2.989387	unique82me	Θ	29.99	132.5	xbox	3
8213067838	125.0	2.989468	unique82me	Θ	29.99	132.5	xbox	3
8213067838	130.0	2.99316	unique82me	Θ	29.99	132.5	xbox	3
8213067838	130.0	2.996516	*champaignbubbles*	202	29.99	132.5	xbox	3
8213067838	132.5	2.996632	*champaignbubbles*	202	29.99	132.5	xbox	3
8213067838	132.5	2.997789	*champaignbubbles*	202	29.99	132.5	xbox	3
8213073509	101.09	2.639931	djfelony	265	1.0	114.5	xbox	3

Val comandos_xboxDF = sqlContext.sql("select distinct bidder from TOTAL_xboxDF where bid>100")



scala> val comandos_xboxDF = sqlContext.sql("select distinct bidder from TOTAL_xboxDF where bid>100")

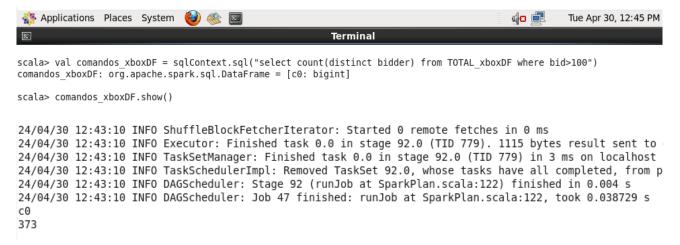


bidder tchick4270 loraron513 darkaqlmax84 tanktabooda daysrus 205 dmsdud kermitthefrock kiflayghiorghis rr6kids jazzjake2005 pjamkeat skcardina biznezb4plezure 42179odie nalinprabhu sno oman daveonbay damon8452 sweetie6684 dbecerraii

Val comandos_xboxDF = sqlContext.sql("select count(distinct bidder) from TOTAL_xboxDF where bid>100")

comandos_xboxDF.show()

La respuesta es que hay 373 distintos



i) Mostrar el precio de todas las subastas con el elemento Xbox implicado (puedes utilitzar el dataframe anterior)



val comandos_xboxDF = sqlContext.sql("select auctionid,bid,bidder,itemtype from TOTAL xboxDF")

comandos xboxDF.show()

