Máster en Big Data

Tecnologías de Almacenamiento 9. Hands-On: Spark

PRESENTADO:

JOSE DAVID ANGULO GARCIA

ALBERT RIPOLL



Índice

1.	Introducción	.3
2.	Entorno	.3
2	Inspección de los datos locales	2



1. Introducción

El objetivo de este Hands-On es el de familiarizarse con una de las librerías más populares del framework de Spark como es SparkSQL

2. Entorno

Para la realización de los ejercicios se va a utilizar *spark-shell* en scala o python ya que nos proporciona un entorno muy dinámico para la introducción de funciones y nos permite recibir una respuesta inmediata.

Para ello, nos descargaremos Spark y levantaremos una spark-shell en local.

Sigue las siguientes instrucciones si es necesario:

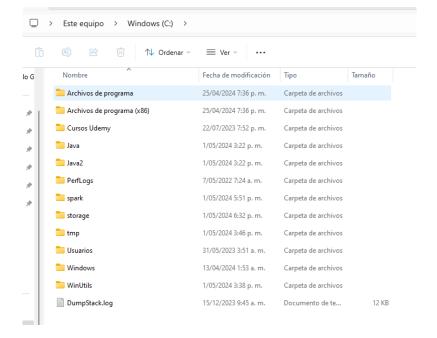
https://sparkbyexamples.com/spark/install-apache-spark-on-mac/

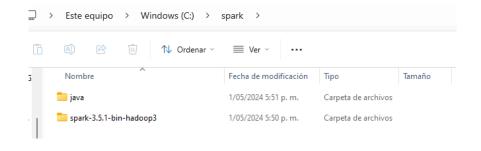
https://sparkbyexamples.com/spark/apache-spark-installation-on-windows/

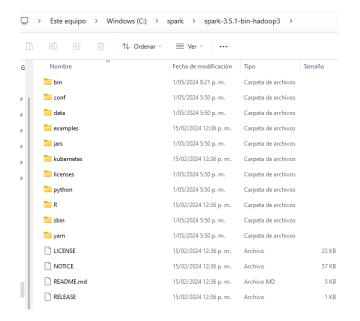
https://sparkbyexamples.com/spark/spark-installation-on-linux-ubuntu/

Configuración del ENTORNO

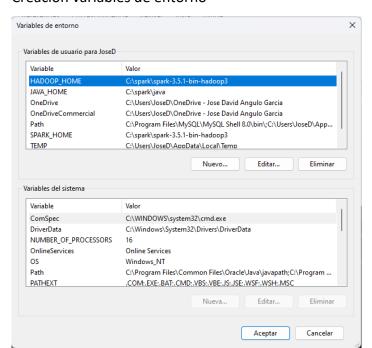
Creación de las carpetas donde se alojarán los instaladores y ficheros



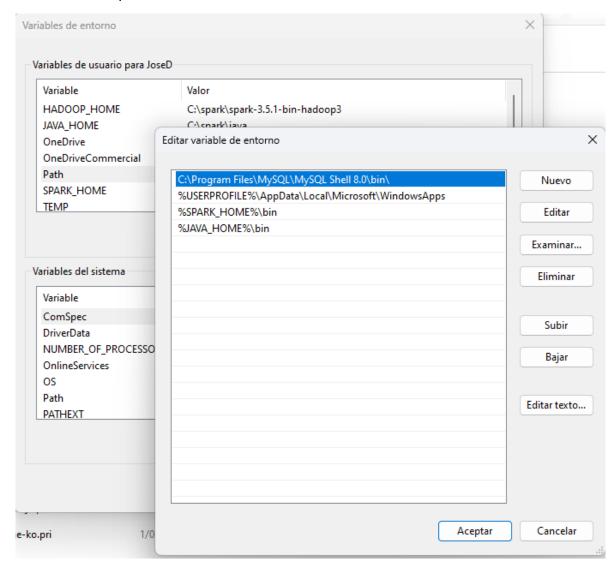




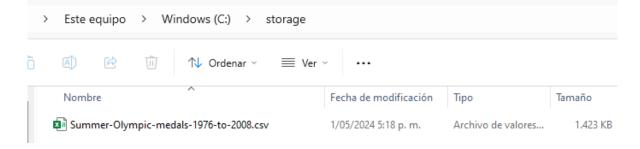
Creación variables de entorno



Creación de los path



Guardamos el dataset a utilizar



Abre un Terminal (en windows preferiblemente PowerShell) apuntando al directorio ../spark-x.y.z-bin-hadoop/bin/

El dataset que utilizaremos se llama Summer-Olympic-medals-1976-to-2008.csv.

```
PowerShell 7.4.2

PS C:\Users\JoseD\Downloads\storage instaladores\PowerShell-7.4.2-win-x64> cd C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS C:\spark\spark-3.5.1-bin-hadoop3\bin PS
```

3. Inspección de los datos locales

Carga el dataset de la siguiente manera (con la ruta del dataset que aplique):

val dataset = spark.read.option("header","true").option("inferSchema",

"true").csv("/path/to/Summer-Olympic-medals-1976-to-2008.csv")

CODIGO:

val olym dataset =

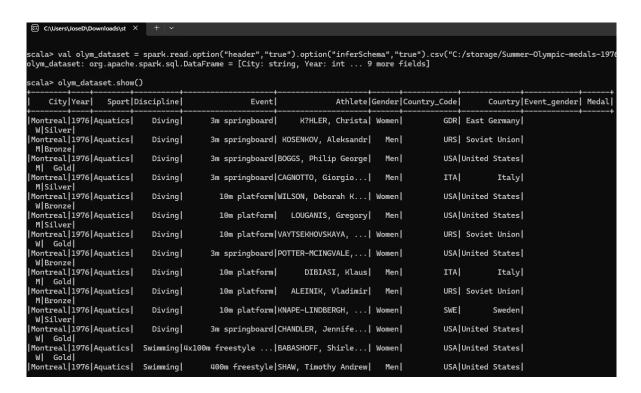
spark.read.option("header","true").option("inferSchema","true").csv("C:/storage/Summer-Olympic-medals-1976-to-2008.csv")

```
Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 22.0.1)
Type in expressions to have them evaluated.
Type :help for more information.

scala> val olym_dataset = spark.read.option("header","true").option("inferSchema","true").csv("C:/storage/Summer-Olympic -medals-1976-to-2008.csv")
olym_dataset: org.apache.spark.sql.DataFrame = [City: string, Year: int ... 9 more fields]
scala>
```

a) Explora el dataset





o) ¿Que han aportado las opciones "header" y "inferSchema"?

olym dataset.head()

Este comando permite ver todos los datos de la primera fila del dataset explorado sin el nombre de las columnes.

olym dataset.schema

permite ver las características que tiene cada columna del dataset como el tipo de dato.



c) ¿Como harías para contar las medallas conseguidas por año y país?

Primero importar la librería de funciones de sql para que el spark pueda interpretar las sentencias que se le van a entregar a través de una variable, donde se agrupara por año y país, contando las medallas que tiene cada uno.

```
scala> import org.apache.spark.sql.functions._
import org.apache.spark.sql.functions._
scala> val totalmedallas = olym_dataset.groupBy("Year","Country").agg(count("Medal"))
totalmedallas: org.apache.spark.sql.DataFrame = [Year: int, Country: string ... 1 more field]
```

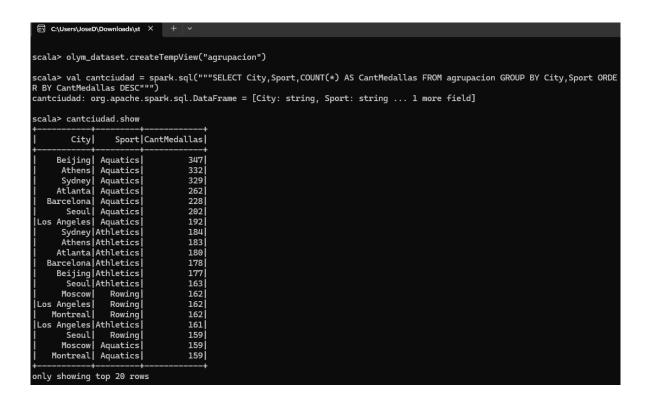


d) Usando SparkSQL muestra alguna métrica interesante.

Para poder ejecutar alguna sentencia select, se debe crear una vista de la variable que contiene el dataset. Y luego crear otra variable que contenta la consulta a realizar. Como sigue:

olym_dataset.createTempView("agrupacion")

val cantciudad = spark.sql("""SELECT City, Sport, COUNT(*) AS CantMedallas FROM agrupacion GROUP BY City, Sport ORDER BY CantMedallas DESC""")

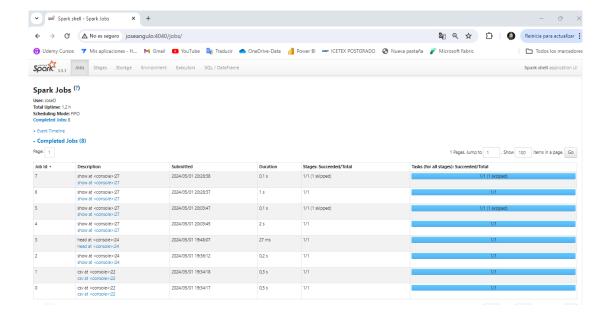


e) ¿Que muestra la SparkUI: http://localhost:4040?

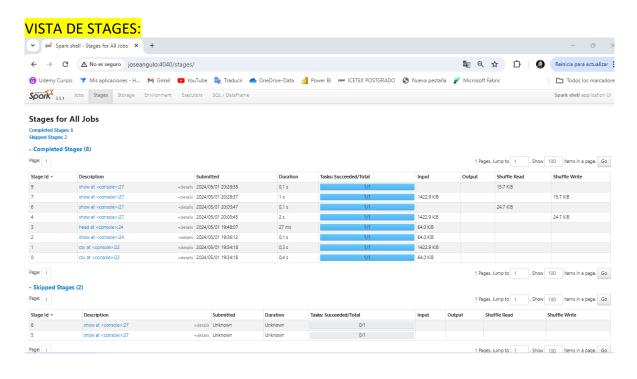
SPARK UI LOCAL: http://joseangulo:4040/jobs/

Observar que cada imagen es la vista de las opciones de arriba de esta pagina: JOBS, STAGES, ENVIROMENT, EXECUTORS, SQL

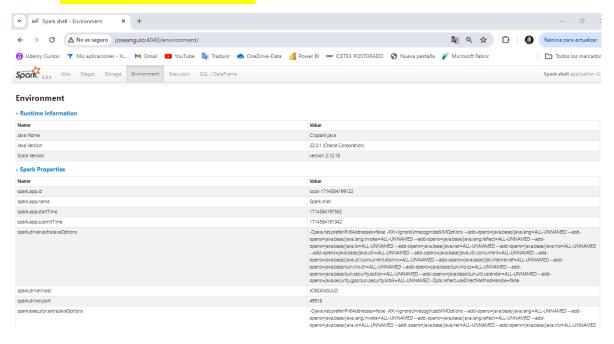
VISTA JOBS: Los Trabajos que se han ejecutado con sus características principales de performance



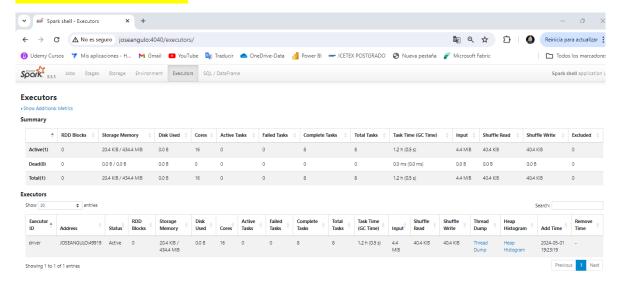




VISTA DE LOS ENVIRONMENT:



VISTA DE LOS EXECUTORS:



VISTA DE SQL:

