# Máster en Big Data

# Tecnologías de Almacenamiento 9. Hands-On: Spark

PRESENTADO:

JOSE DAVID ANGULO GARCIA

ALBERT RIPOLL



## Índice

1.	Introducción	3
2.	Entorno	3
	Inspección de los datos locales	3

#### 1. Introducción

El objetivo de este Hands-On es el de familiarizarse con una de las librerías más populares del framework de Spark como es SparkSQL

#### 2. Entorno

Para la realización de los ejercicios se va a utilizar *spark-shell* en scala o python ya que nos proporciona un entorno muy dinámico para la introducción de funciones y nos permite recibir una respuesta inmediata.

Para ello, nos descargaremos Spark y levantaremos una spark-shell en local.

Sigue las siguientes instrucciones si es necesario:

https://sparkbyexamples.com/spark/install-apache-spark-on-mac/

https://sparkbyexamples.com/spark/apache-spark-installation-on-windows/

https://sparkbyexamples.com/spark/spark-installation-on-linux-ubuntu/

Descarga e instalación del Spark y levantamiento de spark-shell en local.

#### 1) Descargas.

https://www.oracle.com/java/technologies/downloads/#jdk17-windows

Se descarga el "x64 Compressed Archive" selecionando opciones JDK17 y Windows.



#### https://spark.apache.org/downloads.html

Se descarga spark con enlace de opción 3

## Download Apache Spark™

- 1. Choose a Spark release: 3.5.1 (Feb 23 2024) ▼

   2. Choose a package type: Pre-built for Apache Hadoop 3.3 and later ▼
- 3. Download Spark: spark-3.5.1-bin-hadoop3.tgz
- 4. Verify this release using the 3.5.1 signatures, checksums and project release KEYS by following these procedures.

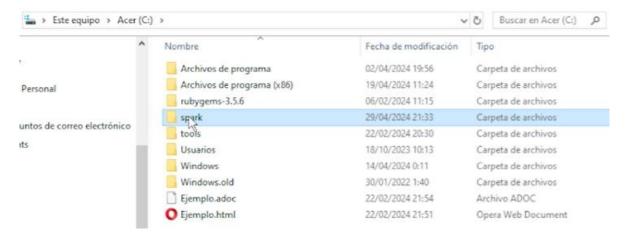


Se descarga winutils con el icono de la derecha



#### 2) Colocación de las descargas.

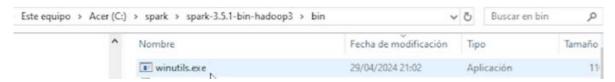
En C: Acer se crea una carpeta llamada "spark"



Dentro de esta carpeta "spark" hemos situado las dos carpetas "jdk-17.0.11" y "spark-3.5.1-bin-hadoop3" de las descargas descomprimidas.



Dentro de "spark-3.5.1-bin-hadoop3" y allí dentro de la carpeta "bin" hemos situado el ejecutable "winutils.exe".

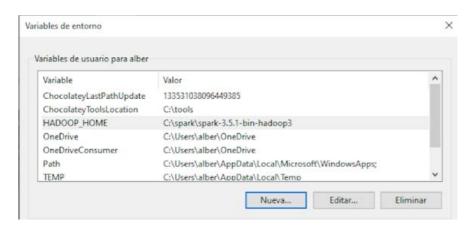


#### 3) Editar variables de entorno de esta cuenta

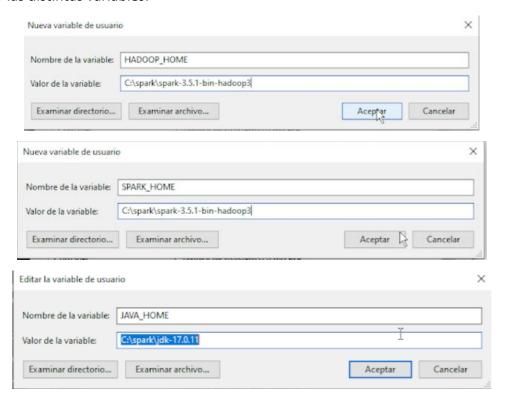
Hemos buscado en Windows la opción "Editar variables de entorno de esta cuenta"



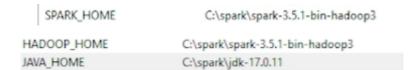
#### Y allí "Nueva"



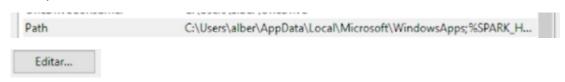
#### Para añadir las distintas variables:



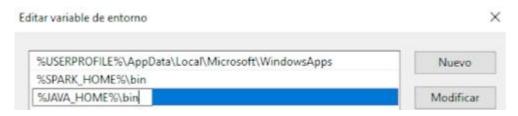
#### Tal que así:



#### En el path le damos a Editar

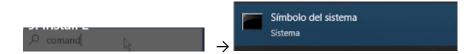


Y en "Nuevo" definimos %SPARK\_HOME%\bin y %JAVA\_HOME%\bin



#### 4) Comprovación de correcta instalación

Vamos al comand prompt



Nos situamos en la carpeta

```
C:\Users\alber>dir C:\spark
El volumen de la unidad C es Acer
El número de serie del volumen es: B82F-6625
 Directorio de C:\spark
29/04/2024
              21:33
                         <DIR>
29/04/2024
              21:33
                         <DIR>
11/03/2024
29/04/2024
                                            jdk-17.0.11
spark-3.5.1-bin-hadoop3
              20:11
                         <DIR>
              21:28
                         <DIR>
                  0 archivos
                                                0 bytes
                  4 dirs 659.941.773.312 bytes libres
```

Vamos a bin

```
C:\Users\alber>cd C:\spark\spark-3.5.1-bin-hadoop3\bin
```

Abrimos spark-shell

```
C:\spark\spark-3.5.1-bin-hadoop3\bin>spark-shell
```

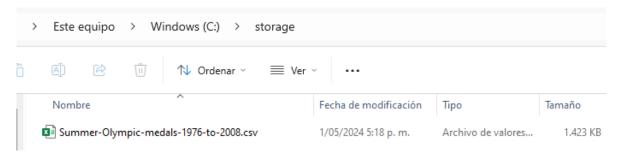
Comprovamos

```
C:\spark\spark-3.5.1-bin-hadoop3>echo %JAVA_HOME%
C:\spark\jdk-17.0.11
```

Ejecutamos spark-shell

```
C:\spark\spark-3.5.1-bin-hadoop3\bin>spark-shell
```

#### 5) Dataset a utilizar





Abre un Terminal (en windows preferiblemente PowerShell) apuntando al directorio ../spark-x.y.z-bin-hadoop/bin/

El dataset que utilizaremos se llama Summer-Olympic-medals-1976-to-2008.csv.

## 3. Inspección de los datos locales

Carga el dataset de la siguiente manera (con la ruta del dataset que aplique):

val dataset = spark.read.option("header", "true").option("inferSchema",

"true").csv("/path/to/Summer-Olympic-medals-1976-to-2008.csv")

#### val olym dataset =

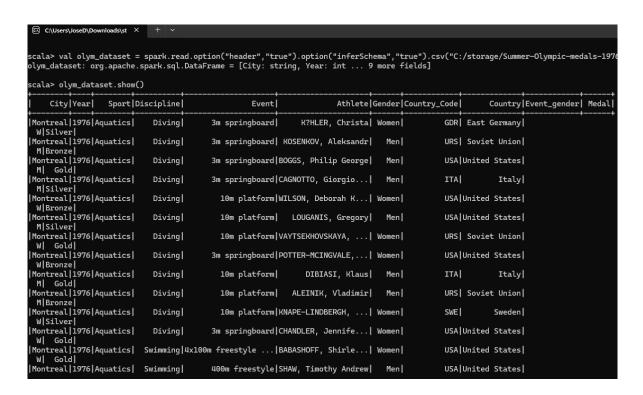
spark.read.option("header","true").option("inferSchema","true").csv("C:/storage/Summer-Olympic-medals-1976-to-2008.csv")

```
Using Scala version 2.12.18 (Java HotSpot(TM) 64-Bit Server VM, Java 22.0.1)
Type in expressions to have them evaluated.
Type :help for more information.

scala> val olym_dataset = spark.read.option("header","true").option("inferSchema","true").csv("C:/storage/Summer-Olympic -medals-1976-to-2008.csv")
olym_dataset: org.apache.spark.sql.DataFrame = [City: string, Year: int ... 9 more fields]
scala>
```

a) Explora el dataset





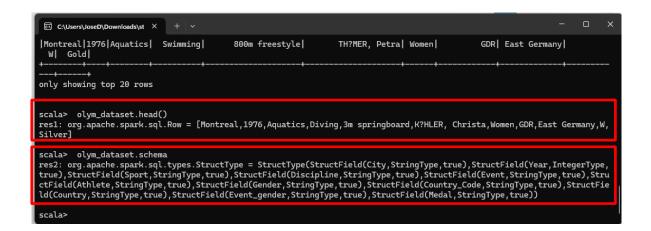
b) ¿Que han aportado las opciones "header" y "inferSchema"?

#### olym dataset.head()

Este comando permite ver todos los datos de la primera fila del dataset explorado sin el nombre de las columnas.

#### olym dataset.schema

Permite ver las características que tiene cada columna del dataset como el tipo de dato.





#### c) ¿Como harías para contar las medallas conseguidas por año y país?

Primero importar la librería de funciones de sql para que el spark pueda interpretar las sentencias que se le van a entregar a través de una variable, donde se agrupara por año y país, contando las medallas que tiene cada uno.

```
scala> import org.apache.spark.sql.functions._
import org.apache.spark.sql.functions._
scala> val totalmedallas = olym_dataset.groupBy("Year","Country").agg(count("Medal"))
totalmedallas: org.apache.spark.sql.DataFrame = [Year: int, Country: string ... 1 more field]
```

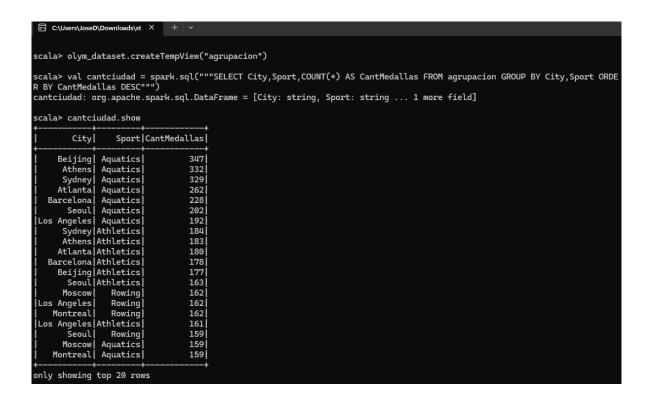


#### d) Usando SparkSQL muestra alguna métrica interesante.

Para poder ejecutar alguna sentencia select, se debe crear una vista de la variable que contiene el dataset. Y luego crear otra variable que contenta la consulta a realizar. Como sigue:

olym\_dataset.createTempView("agrupacion")

val cantciudad = spark.sql("""SELECT City, Sport, COUNT(\*) AS CantMedallas FROM agrupacion GROUP BY City, Sport ORDER BY CantMedallas DESC""")

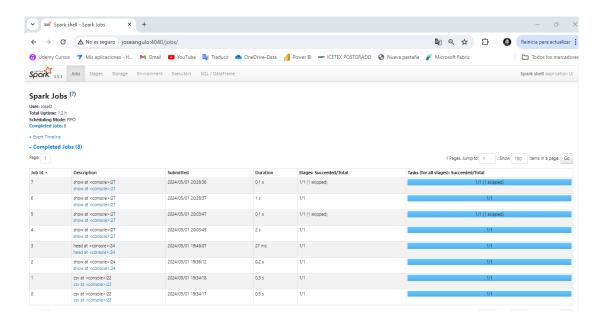


e) ¿Que muestra la SparkUI: <a href="http://localhost:4040">http://localhost:4040</a>?

SPARK UI LOCAL: http://joseangulo:4040/jobs/

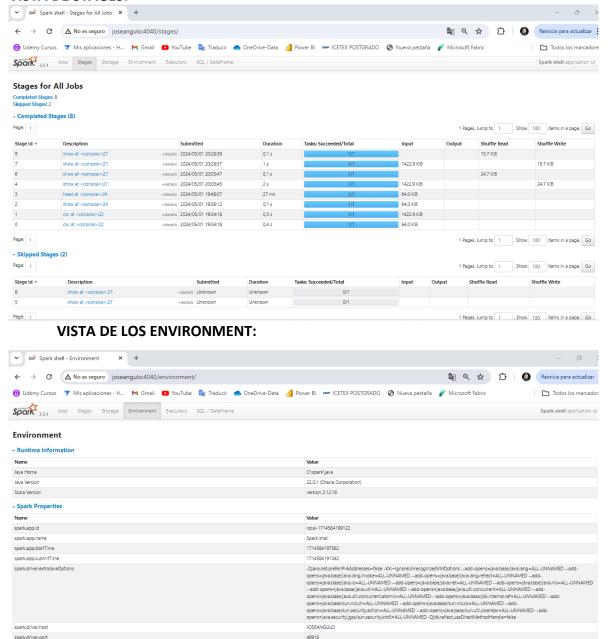
Observar que cada imagen es la vista de las opciones de arriba de esta pagina: JOBS, STAGES, ENVIROMENT, EXECUTORS, SQL

VISTA JOBS: Los Trabajos que se han ejecutado con sus características principales de performance.





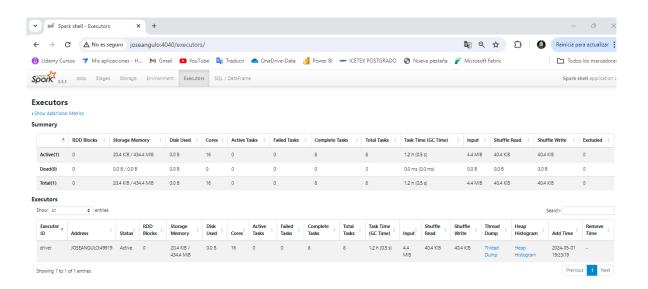
#### **VISTA DE STAGES:**



#### **VISTA DE LOS EXECUTORS:**

spark.executor.extraJavaOptions

- Ojava.net.preferiPréAddresses-faise - VX-i-gonoret.brecognized/WOptions -- add-opens-java.base/java.lang=ALL-UNNAMED -- add-opens-java.base/java.lang.inchez-ALL-UNNAMED -- add-opens-java.base/java.lang.inchez-ALL-UNNAMED -- add-opens-java.base/java.lang.referta-ALL-UNNAMED -- add-opens-java.base/java.no-ALL-UNNAMED -- add-opens-java.base/java.bas



#### **VISTA DE SQL:**

